

Teoría de Probabilidad

Maestría en Estadística Aplicada

Julio Hurtado, Msc.

UTB

2020



Variables aleatorias – Parte 8

- 1 Algunas importantes Variables Aleatorias Discretas
- 2 Algunas importantes Variables Aleatorias Continuas.
- 3 Distribuciones Bivariadas
- 4 Distribuciones Multivariadas
 - Dos Importantes Distribuciones Multivariadas
 - Transformación de Variables Aleatorias
 - Ejercicios



- Enlazar espacios muestrales y eventos a los datos, es proporcionado por el concepto de **Variables Aleatorias**.
- Una **variable aleatoria** es una función $X : \Omega \rightarrow \mathbb{R}$ que asigna a un número real para cada resultado ω .
- **Ejemplo** Lanzamos una moneda 10 veces. Sea $X(\omega)$ el número de caras en la secuencia ω . Por ejemplo si $\omega = HHTHHTHHTT$, entonces $X(\omega) = 6$.
- **Ejemplo** Lancemos dos monedas y sea X el número de caras. Entonces, $\mathbb{P}(X = 0) = \mathbb{P}(\{TT\}) = 1/4$, $\mathbb{P}(X = 1) = \mathbb{P}(\{HT, TH\}) = 1/2$ y $\mathbb{P}(X = 2) = \mathbb{P}(\{HH\}) = 1/4$. Las variables aleatorias y su distribución puede ser resumida como sigue:
-



- Enlazar espacios muestrales y eventos a los datos, es proporcionado por el concepto de **Variables Aleatorias**.
- Una **variable aleatoria** es una función $X : \Omega \rightarrow \mathbb{R}$ que asigna a un número real para cada resultado ω .
- **Ejemplo** Lanzamos una moneda 10 veces. Sea $X(\omega)$ el número de caras en la secuencia ω . Por ejemplo si $\omega = HHTHHTHHTT$, entonces $X(\omega) = 6$.
- **Ejemplo** Lancemos dos monedas y sea X el número de caras. Entonces, $\mathbb{P}(X = 0) = \mathbb{P}(\{TT\}) = 1/4$, $\mathbb{P}(X = 1) = \mathbb{P}(\{HT, TH\}) = 1/2$ y $\mathbb{P}(X = 2) = \mathbb{P}(\{HH\}) = 1/4$. Las variables aleatorias y su distribución puede ser resumida como sigue:
-



- Enlazar espacios muestrales y eventos a los datos, es proporcionado por el concepto de **Variables Aleatorias**.
- Una **variable aleatoria** es una función $X : \Omega \rightarrow \mathbb{R}$ que asigna a un número real para cada resultado ω .
- **Ejemplo** Lanzamos una moneda 10 veces. Sea $X(\omega)$ el número de caras en la secuencia ω . Por ejemplo si $\omega = HHTHHTHHTT$, entonces $X(\omega) = 6$.
- **Ejemplo** Lancemos dos monedas y sea X el número de caras. Entonces, $\mathbb{P}(X = 0) = \mathbb{P}(\{TT\}) = 1/4$, $\mathbb{P}(X = 1) = \mathbb{P}(\{HT, TH\}) = 1/2$ y $\mathbb{P}(X = 2) = \mathbb{P}(\{HH\}) = 1/4$. Las variables aleatorias y su distribución puede ser resumida como sigue:



- Enlazar espacios muestrales y eventos a los datos, es proporcionado por el concepto de **Variables Aleatorias**.
- Una **variable aleatoria** es una función $X : \Omega \rightarrow \mathbb{R}$ que asigna a un número real para cada resultado ω .
- **Ejemplo** Lanzamos una moneda 10 veces. Sea $X(\omega)$ el número de caras en la secuencia ω . Por ejemplo si $\omega = HHTHHTHHTT$, entonces $X(\omega) = 6$.
- **Ejemplo** Lancemos dos monedas y sea X el número de caras. Entonces, $\mathbb{P}(X = 0) = \mathbb{P}(\{TT\}) = 1/4$, $\mathbb{P}(X = 1) = \mathbb{P}(\{HT, TH\}) = 1/2$ y $\mathbb{P}(X = 2) = \mathbb{P}(\{HH\}) = 1/4$. Las variables aleatorias y su distribución puede ser resumida como sigue:



- Enlazar espacios muestrales y eventos a los datos, es proporcionado por el concepto de **Variables Aleatorias**.
- Una **variable aleatoria** es una función $X : \Omega \rightarrow \mathbb{R}$ que asigna a un número real para cada resultado ω .
- **Ejemplo** Lanzamos una moneda 10 veces. Sea $X(\omega)$ el número de caras en la secuencia ω . Por ejemplo si $\omega = HHTHHTHHTT$, entonces $X(\omega) = 6$.
- **Ejemplo** Lancemos dos monedas y sea X el número de caras. Entonces, $\mathbb{P}(X = 0) = \mathbb{P}(\{TT\}) = 1/4$,
 $\mathbb{P}(X = 1) = \mathbb{P}(\{HT, TH\}) = 1/2$ y $\mathbb{P}(X = 2) = \mathbb{P}(\{HH\}) = 1/4$. Las variables aleatorias y su distribución puede ser resumida como sigue:



ω	$\mathbb{P}(\{\omega\})$	$X(\omega)$
TT	1/4	0
TH	1/4	1
HT	1/4	1
HH	1/4	2

x	$\mathbb{P}(X = x)$
0	1/4
1	1/2
2	1/4



ω	$\mathbb{P}(\{\omega\})$	$X(\omega)$
TT	1/4	0
TH	1/4	1
HT	1/4	1
HH	1/4	2

x	$\mathbb{P}(X = x)$
0	1/4
1	1/2
2	1/4



- Dada una variable aleatoria X y un subconjunto A de la línea real, definamos $X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\}$ y sea

$$\mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A)) = \mathbb{P}(\{\omega \in \Omega; X(\omega) \in A\})$$

$$\mathbb{P}(X = x) = \mathbb{P}(X^{-1}(x)) = \mathbb{P}(\{\omega \in \Omega; X(\omega) = x\}).$$

- Función Distribución y Función de Probabilidad
- **Definición** La *Función Distribución Acumulativa* o CDF, es la función $F_X : \mathbb{R} \rightarrow [0, 1]$ es definido como

$$F_X(x) = \mathbb{P}(X \leq x). \quad (1)$$



- Dada una variable aleatoria X y un subconjunto A de la línea real, definamos $X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\}$ y sea

$$\mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A)) = \mathbb{P}(\{\omega \in \Omega; X(\omega) \in A\})$$

$$\mathbb{P}(X = x) = \mathbb{P}(X^{-1}(x)) = \mathbb{P}(\{\omega \in \Omega; X(\omega) = x\}).$$

- **Función Distribución y Función de Probabilidad**

- **Definición** La *Función Distribución Acumulativa* o CDF, es la función $F_X : \mathbb{R} \rightarrow [0, 1]$ es definido como

$$F_X(x) = \mathbb{P}(X \leq x). \quad (1)$$



- Dada una variable aleatoria X y un subconjunto A de la línea real, definamos $X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\}$ y sea

$$\mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A)) = \mathbb{P}(\{\omega \in \Omega; X(\omega) \in A\})$$

$$\mathbb{P}(X = x) = \mathbb{P}(X^{-1}(x)) = \mathbb{P}(\{\omega \in \Omega; X(\omega) = x\}).$$

- Función Distribución y Función de Probabilidad
- **Definición** La *Función Distribución Acumulativa* o CDF, es la función $F_X : \mathbb{R} \rightarrow [0, 1]$ es definido como

$$F_X(x) = \mathbb{P}(X \leq x). \quad (1)$$



- Dada una variable aleatoria X y un subconjunto A de la línea real, definamos $X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\}$ y sea

$$\mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A)) = \mathbb{P}(\{\omega \in \Omega; X(\omega) \in A\})$$

$$\mathbb{P}(X = x) = \mathbb{P}(X^{-1}(x)) = \mathbb{P}(\{\omega \in \Omega; X(\omega) = x\}).$$

- Función Distribución y Función de Probabilidad
- **Definición** La *Función Distribución Acumulativa* o CDF, es la función $F_X : \mathbb{R} \rightarrow [0, 1]$ es definido como

$$F_X(x) = \mathbb{P}(X \leq x). \quad (1)$$



- Los siguientes resultados muestran que la CDF completamente determina la distribución de una variable aleatoria.

- 1 Sea X que tiene un CDF F y sea Y que tiene CDF G . Si $F(x) = G(x)$ para todo x , entonces $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo A .
- 2 Una función $F : \mathbb{R} \rightarrow [0, 1]$ es un CDF para alguna probabilidad \mathbb{P} si y sólo si se cumplen las siguientes condiciones

- 1 F es no decreciente: $x_1 < x_2$ implica $F(x_1) \leq F(x_2)$.

- 2 F es normalizado:

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

y

$$\lim_{x \rightarrow \infty} F(x) = 1$$

- 3 F es continua por la derecha: $F(x) = F(x^+)$ para todo x , donde

$$F(x^+) = \lim_{y \rightarrow x} F(y) \quad \text{si} \quad y > x.$$



- Los siguientes resultados muestran que la CDF completamente determina la distribución de una variable aleatoria.

- 1 Sea X que tiene un CDF F y sea Y que tiene CDF G . Si $F(x) = G(x)$ para todo x , entonces $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo A .
- 2 Una función $F : \mathbb{R} \rightarrow [0, 1]$ es un CDF para alguna probabilidad \mathbb{P} si y sólo si se cumplen las siguientes condiciones

1 F es no decreciente: $x_1 < x_2$ implica $F(x_1) \leq F(x_2)$.

2 F es normalizado:

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

y

$$\lim_{x \rightarrow \infty} F(x) = 1$$

3 F es continua por la derecha: $F(x) = F(x^+)$ para todo x , donde

$$F(x^+) = \lim_{y \rightarrow x} F(y) \quad \text{si} \quad y > x.$$



- Los siguientes resultados muestran que la CDF completamente determina la distribución de una variable aleatoria.

- 1 Sea X que tiene un CDF F y sea Y que tiene CDF G . Si $F(x) = G(x)$ para todo x , entonces $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo A .
- 2 Una función $F : \mathbb{R} \rightarrow [0, 1]$ es un CDF para alguna probabilidad \mathbb{P} si y sólo si se cumplen las siguientes condiciones

- 1 F es no decreciente: $x_1 < x_2$ implica $F(x_1) \leq F(x_2)$.

- 2 F es normalizado:

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

y

$$\lim_{x \rightarrow \infty} F(x) = 1$$

- 3 F es continua por la derecha: $F(x) = F(x^+)$ para todo x , donde

$$F(x^+) = \lim_{y \rightarrow x} F(y) \quad \text{si} \quad y > x.$$



- Los siguientes resultados muestran que la CDF completamente determina la distribución de una variable aleatoria.

- 1 Sea X que tiene un CDF F y sea Y que tiene CDF G . Si $F(x) = G(x)$ para todo x , entonces $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo A .
- 2 Una función $F : \mathbb{R} \rightarrow [0, 1]$ es un CDF para alguna probabilidad \mathbb{P} si y sólo si se cumplen las siguientes condiciones

1 F es no decreciente: $x_1 < x_2$ implica $F(x_1) \leq F(x_2)$.

2 F es normalizado:

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

y

$$\lim_{x \rightarrow \infty} F(x) = 1$$

3 F es continua por la derecha: $F(x) = F(x^+)$ para todo x , donde

$$F(x^+) = \lim_{y \rightarrow x} F(y) \quad \text{si} \quad y > x.$$



- Los siguientes resultados muestran que la CDF completamente determina la distribución de una variable aleatoria.

- 1 Sea X que tiene un CDF F y sea Y que tiene CDF G . Si $F(x) = G(x)$ para todo x , entonces $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo A .
- 2 Una función $F : \mathbb{R} \rightarrow [0, 1]$ es un CDF para alguna probabilidad \mathbb{P} si y sólo si se cumplen las siguientes condiciones

- 1 F es no decreciente: $x_1 < x_2$ implica $F(x_1) \leq F(x_2)$.

- 2 F es normalizado:

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

y

$$\lim_{x \rightarrow \infty} F(x) = 1$$

- 3 F es continua por la derecha: $F(x) = F(x^+)$ para todo x , donde

$$F(x^+) = \lim_{y \rightarrow x} F(y) \quad \text{si} \quad y > x.$$



- Los siguientes resultados muestran que la CDF completamente determina la distribución de una variable aleatoria.

- 1 Sea X que tiene un CDF F y sea Y que tiene CDF G . Si $F(x) = G(x)$ para todo x , entonces $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo A .
- 2 Una función $F : \mathbb{R} \rightarrow [0, 1]$ es un CDF para alguna probabilidad \mathbb{P} si y sólo si se cumplen las siguientes condiciones

- 1 F es no decreciente: $x_1 < x_2$ implica $F(x_1) \leq F(x_2)$.

- 2 F es normalizado:

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

y

$$\lim_{x \rightarrow \infty} F(x) = 1$$

- 3 F es continua por la derecha: $F(x) = F(x^+)$ para todo x , donde

$$F(x^+) = \lim_{y \rightarrow x} F(y) \quad \text{si} \quad y > x.$$



- Los siguientes resultados muestran que la CDF completamente determina la distribución de una variable aleatoria.

- 1 Sea X que tiene un CDF F y sea Y que tiene CDF G . Si $F(x) = G(x)$ para todo x , entonces $\mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$ para todo A .
- 2 Una función $F : \mathbb{R} \rightarrow [0, 1]$ es un CDF para alguna probabilidad \mathbb{P} si y sólo si se cumplen las siguientes condiciones

- 1 F es no decreciente: $x_1 < x_2$ implica $F(x_1) \leq F(x_2)$.

- 2 F es normalizado:

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

y

$$\lim_{x \rightarrow \infty} F(x) = 1$$

- 3 F es continua por la derecha: $F(x) = F(x^+)$ para todo x , donde


$$F(x^+) = \lim_{y \rightarrow x} F(y) \quad \text{si} \quad y > x.$$



- **Ejemplo** Lanzamos una moneda dos veces y sea X el número de caras. Entonces $\mathbb{P}(X = 0) = \mathbb{P}(X = 2) = 1/4$ y $\mathbb{P}(X = 1) = 1/2$. La función distribución es

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1/4 & 0 \leq x < 1 \\ 3/4 & 1 \leq x < 2 \\ 1 & x \geq 2. \end{cases}$$


- y el CDF es mostrado en la siguiente figura. Se debe notar que la función es continua por la derecha, no decreciente y es definida para todo x , incluso si la variable aleatoria toma los valores 0, 1 y 2.



- **Ejemplo** Lanzamos una moneda dos veces y sea X el número de caras. Entonces $\mathbb{P}(X = 0) = \mathbb{P}(X = 2) = 1/4$ y $\mathbb{P}(X = 1) = 1/2$. La función distribución es

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1/4 & 0 \leq x < 1 \\ 3/4 & 1 \leq x < 2 \\ 1 & x \geq 2. \end{cases}$$


- y el CDF es mostrado en la siguiente figura. Se debe notar que la función es continua por la derecha, no decreciente y es definida para todo x , incluso si la variable aleatoria toma los valores 0, 1 y 2.



- **Ejemplo** Lanzamos una moneda dos veces y sea X el número de caras. Entonces $\mathbb{P}(X = 0) = \mathbb{P}(X = 2) = 1/4$ y $\mathbb{P}(X = 1) = 1/2$. La función distribución es

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1/4 & 0 \leq x < 1 \\ 3/4 & 1 \leq x < 2 \\ 1 & x \geq 2. \end{cases}$$


- y el CDF es mostrado en la siguiente figura. Se debe notar que la función es continua por la derecha, no decreciente y es definida para todo x , incluso si la variable aleatoria toma los valores 0, 1 y 2.



- **Ejemplo** Lanzamos una moneda dos veces y sea X el número de caras. Entonces $\mathbb{P}(X = 0) = \mathbb{P}(X = 2) = 1/4$ y $\mathbb{P}(X = 1) = 1/2$. La función distribución es

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1/4 & 0 \leq x < 1 \\ 3/4 & 1 \leq x < 2 \\ 1 & x \geq 2. \end{cases}$$


- y el CDF es mostrado en la siguiente figura. Se debe notar que la función es continua por la derecha, no decreciente y es definida para todo x , incluso si la variable aleatoria toma los valores 0, 1 y 2.



- **Ejemplo** Lanzamos una moneda dos veces y sea X el número de caras. Entonces $\mathbb{P}(X = 0) = \mathbb{P}(X = 2) = 1/4$ y $\mathbb{P}(X = 1) = 1/2$. La función distribución es

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1/4 & 0 \leq x < 1 \\ 3/4 & 1 \leq x < 2 \\ 1 & x \geq 2. \end{cases}$$

- y el CDF es mostrado en la siguiente figura. Se debe notar que la función es continua por la derecha, no decreciente y es definida para todo x , incluso si la variable aleatoria toma los valores 0, 1 y 2.



- **Definición** Si X es discreta si toma valores contables $\{x_1, x_2, \dots\}$. Definimos la **función probabilidad** o **pmf** para X por $f_X(x) = \mathbb{P}(X = x)$.

Así, $f_X(x) \geq 0$ para todo $x \in \mathbb{R}$ y $\sum_i f_X(x_i) = 1$. El CDF es relacionado a f_X por

$$F_X(x) = \mathbb{P}(X \leq x) = \sum_{x_i \leq x} f_X(x_i).$$

La función probabilidad para el ejemplo anterior es

$$f_X(x) = \begin{cases} 1/4 & x = 0 \\ 1/2 & x = 1 \\ 1/4 & x = 2 \\ 0 & \text{en otros casos.} \end{cases}$$



- **Definición** Si X es discreta si toma valores contables $\{x_1, x_2, \dots\}$. Definimos la **función probabilidad** o **pmf** para X por $f_X(x) = \mathbb{P}(X = x)$.

Así, $f_X(x) \geq 0$ para todo $x \in \mathbb{R}$ y $\sum_i f_X(x_i) = 1$. El CDF es relacionado a f_X por


$$F_X(x) = \mathbb{P}(X \leq x) = \sum_{x_i \leq x} f_X(x_i).$$

La función probabilidad para el ejemplo anterior es

$$f_X(x) = \begin{cases} 1/4 & x = 0 \\ 1/2 & x = 1 \\ 1/4 & x = 2 \\ 0 & \text{en otros casos.} \end{cases}$$



- Como indica la siguiente figura




- **Definición** Una variable aleatoria es **continua** si existe una función f_X tal que $f_X(x) \geq 0$ para todo x , $\int_{-\infty}^{\infty} f_X(x)dx = 1$ y para todo $a \leq b$,

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x)dx. \quad (2)$$



- Como indica la siguiente figura




- **Definición** Una variable aleatoria es **continua** si existe una función f_X tal que $f_X(x) \geq 0$ para todo x , $\int_{-\infty}^{\infty} f_X(x)dx = 1$ y para todo $a \leq b$,

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x)dx. \quad (2)$$



- Como indica la siguiente figura



- **Definición** Una variable aleatoria es **continua** si existe una función f_X tal que $f_X(x) \geq 0$ para todo x , $\int_{-\infty}^{\infty} f_X(x)dx = 1$ y para todo $a \leq b$,

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x)dx. \quad (2)$$



- La función f_X es llamada **función densidad de probabilidad (PDF)**.
Tenemos que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

y $f_X(x) = F'_X(x)$ para todos los puntos x donde F_X es diferenciable.

- **Ejemplo** Supongase que X tiene PDF

$$f_X(x) = \begin{cases} 1 & \text{para } 0 \leq x < 1 \\ 0 & \text{en otros casos} \end{cases}$$



- La función f_X es llamada **función densidad de probabilidad (PDF)**.
Tenemos que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

y $f_X(x) = F'_X(x)$ para todos los puntos x donde F_X es diferenciable.

- **Ejemplo** Supongase que X tiene PDF

$$f_X(x) = \begin{cases} 1 & \text{para } 0 \leq x < 1 \\ 0 & \text{en otros casos} \end{cases}$$



- La función f_X es llamada **función densidad de probabilidad (PDF)**.
Tenemos que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

y $f_X(x) = F'_X(x)$ para todos los puntos x donde F_X es diferenciable.

- **Ejemplo** Supongase que X tiene PDF


$$f_X(x) = \begin{cases} 1 & \text{para } 0 \leq x < 1 \\ 0 & \text{en otros casos} \end{cases}$$



- Claramente $f_X \geq 0$ y $\int f_X(x)dx = 1$. Una variable aleatoria con esta densidad se dice que tiene una distribución uniforme (Uniform(0,1)), lo que captura la idea, de escoger un punto entre 0 y 1. El CDF está dado por

$$F_X(x) = \begin{cases} 0 & x < 0 \\ x & 0 \leq x \leq 1 \\ 1 & x > 1. \end{cases}$$


y cuyo gráfico es



- Claramente $f_X \geq 0$ y $\int f_X(x)dx = 1$. Una variable aleatoria con esta densidad se dice que tiene una distribución uniforme (Uniform(0,1)), lo que captura la idea, de escoger un punto entre 0 y 1. El CDF está dado por

$$F_X(x) = \begin{cases} 0 & x < 0 \\ x & 0 \leq x \leq 1 \\ 1 & x > 1. \end{cases}$$

y cuyo gráfico es



- **Ejemplo** Supongamos que X tiene PDF

$$f(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{1}{(1+x)^2} & \text{en otros casos.} \end{cases}$$

Desde que $\int f(x)dx = 1$ esta es una bien definida PDF.

Observaciones

- 1 Si X es continua, entonces $\mathbb{P}(X = x) = 0$ para cada x .
- 2 No se debe pensar $f(x)$ como $\mathbb{P}(X = x)$. Esto se cumple, para variables aleatorias discretas.



- **Ejemplo** Supongamos que X tiene PDF

$$f(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{1}{(1+x)^2} & \text{en otros casos.} \end{cases}$$

Desde que $\int f(x)dx = 1$ esta es una bien definida PDF.

Observaciones

- 1 Si X es continua, entonces $\mathbb{P}(X = x) = 0$ para cada x .
- 2 No se debe pensar $f(x)$ como $\mathbb{P}(X = x)$. Esto se cumple, para variables aleatorias discretas.



- **Ejemplo** Supongamos que X tiene PDF

$$f(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{1}{(1+x)^2} & \text{en otros casos.} \end{cases}$$

Desde que $\int f(x)dx = 1$ esta es una bien definida PDF.

Observaciones

- 1 Si X es continua, entonces $\mathbb{P}(X = x) = 0$ para cada x .
- 2 No se debe pensar $f(x)$ como $\mathbb{P}(X = x)$. Esto se cumple, para variables aleatorias discretas.



- **Ejemplo** Supongamos que X tiene PDF

$$f(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{1}{(1+x)^2} & \text{en otros casos.} \end{cases}$$

Desde que $\int f(x)dx = 1$ esta es una bien definida PDF.

Observaciones

- 1 Si X es continua, entonces $\mathbb{P}(X = x) = 0$ para cada x .
- 2 No se debe pensar $f(x)$ como $\mathbb{P}(X = x)$. Esto se cumple, para variables aleatorias discretas.



• Ejemplo Sea

$$f(x) = \begin{cases} 0 & x < 0 \\ \frac{1}{(1+x)} & \text{en otros casos.} \end{cases}$$

Esto no es un PDF, desde que $\int f(x)dx = \log \infty = \infty$.

Teorema Sea F el CDF una variable aleatoria X . Entonces

- 1 $\mathbb{P}(X = x) = F(x) - F(x^-)$, donde $F(x^-) = \lim_{y \rightarrow x^-} F(y)$ si $y < x$ ($\lim_{y \uparrow x} F(y)$).
- 2 $\mathbb{P}(x < X \leq y) = F(y) - F(x)$
- 3 $\mathbb{P}(X > x) = 1 - F(x)$
- 4 Si X es continua, entonces

$$\begin{aligned} F(b) - F(a) &= \mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) \end{aligned}$$



• Ejemplo Sea

$$f(x) = \begin{cases} 0 & x < 0 \\ \frac{1}{(1+x)} & \text{en otros casos.} \end{cases}$$

Esto no es un PDF, desde que $\int f(x)dx = \log \infty = \infty$.

Teorema Sea F el CDF una variable aleatoria X . Entonces

- ① $\mathbb{P}(X = x) = F(x) - F(x^-)$, donde
 $F(x^-) = \lim_{y \rightarrow x^-} F(y)$ si $y < x$ ($\lim_{y \uparrow x} F(y)$).
- ② $\mathbb{P}(x < X \leq y) = F(y) - F(x)$
- ③ $\mathbb{P}(X > x) = 1 - F(x)$
- ④ Si X es continua, entonces

$$\begin{aligned} F(b) - F(a) &= \mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) \end{aligned}$$



• Ejemplo Sea

$$f(x) = \begin{cases} 0 & x < 0 \\ \frac{1}{(1+x)} & \text{en otros casos.} \end{cases}$$

Esto no es un PDF, desde que $\int f(x)dx = \log \infty = \infty$.

Teorema Sea F el CDF una variable aleatoria X . Entonces

- 1 $\mathbb{P}(X = x) = F(x) - F(x^-)$, donde
 $F(x^-) = \lim_{y \rightarrow x^-} F(y)$ si $y < x$ ($\lim_{y \uparrow x} F(y)$).
- 2 $\mathbb{P}(x < X \leq y) = F(y) - F(x)$
- 3 $\mathbb{P}(X > x) = 1 - F(x)$
- 4 Si X es continua, entonces

$$\begin{aligned} F(b) - F(a) &= \mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) \end{aligned}$$



• Ejemplo Sea

$$f(x) = \begin{cases} 0 & x < 0 \\ \frac{1}{(1+x)} & \text{en otros casos.} \end{cases}$$

Esto no es un PDF, desde que $\int f(x)dx = \log \infty = \infty$.

Teorema Sea F el CDF una variable aleatoria X . Entonces

- 1 $\mathbb{P}(X = x) = F(x) - F(x^-)$, donde
 $F(x^-) = \lim_{y \rightarrow x^-} F(y)$ si $y < x$ ($\lim_{y \uparrow x} F(y)$).
- 2 $\mathbb{P}(x < X \leq y) = F(y) - F(x)$
- 3 $\mathbb{P}(X > x) = 1 - F(x)$
- 4 Si X es continua, entonces

$$\begin{aligned} F(b) - F(a) &= \mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) \end{aligned}$$



• Ejemplo Sea

$$f(x) = \begin{cases} 0 & x < 0 \\ \frac{1}{(1+x)} & \text{en otros casos.} \end{cases}$$

Esto no es un PDF, desde que $\int f(x)dx = \log \infty = \infty$.

Teorema Sea F el CDF una variable aleatoria X . Entonces

- 1 $\mathbb{P}(X = x) = F(x) - F(x^-)$, donde $F(x^-) = \lim_{y \rightarrow x^-} F(y)$ si $y < x$ ($\lim_{y \uparrow x} F(y)$).
- 2 $\mathbb{P}(x < X \leq y) = F(y) - F(x)$
- 3 $\mathbb{P}(X > x) = 1 - F(x)$
- 4 Si X es continua, entonces

$$\begin{aligned} F(b) - F(a) &= \mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) \end{aligned}$$



• Ejemplo Sea

$$f(x) = \begin{cases} 0 & x < 0 \\ \frac{1}{(1+x)} & \text{en otros casos.} \end{cases}$$

Esto no es un PDF, desde que $\int f(x)dx = \log \infty = \infty$.

Teorema Sea F el CDF una variable aleatoria X . Entonces

- 1 $\mathbb{P}(X = x) = F(x) - F(x^-)$, donde
 $F(x^-) = \lim_{y \rightarrow x^-} F(y)$ si $y < x$ ($\lim_{y \uparrow x} F(y)$).
- 2 $\mathbb{P}(x < X \leq y) = F(y) - F(x)$
- 3 $\mathbb{P}(X > x) = 1 - F(x)$
- 4 Si X es continua, entonces

$$\begin{aligned} F(b) - F(a) &= \mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) \end{aligned}$$



- Definamos la inversa CDF, o **función cuantil**

Definición Sea X una variable aleatoria con CDF F . La *inversa CDF* o *función cuantil* es definida como

$$F^{-1}(q) = \inf\{x : F(x) > q\}$$

para $q \in [0, 1]$. Si F es estrictamente creciente y continua, entonces $F^{-1}(q)$ es el único número real x tal que $F(x) = q$.

Llamamos $F^{-1}(1/4)$ el *el primer cuartil*, $F^{-1}(1/2)$ la *mediana* o *segundo cuartil* y $F^{-1}(3/4)$, el *tercer cuartil*.

Dos variables aleatorias X y Y son **iguales en distribución** si $F_X(x) = F_Y(y)$ para todo x . Esto significa que las aseveraciones de probabilidad acerca de X y Y deben ser las mismas.



- Definamos la inversa CDF, o **función cuantil**

Definición Sea X una variable aleatoria con CDF F . La *inversa CDF* o *función cuantil* es definida como

$$F^{-1}(q) = \inf\{x : F(x) > q\}$$

para $q \in [0, 1]$. Si F es estrictamente creciente y continua, entonces $F^{-1}(q)$ es el único número real x tal que $F(x) = q$.

Llamamos $F^{-1}(1/4)$ el *el primer cuartil*, $F^{-1}(1/2)$ la *mediana* o *segundo cuartil* y $F^{-1}(3/4)$, el *tercer cuartil*.

Dos variables aleatorias X y Y son **iguales en distribución** si $F_X(x) = F_Y(y)$ para todo x . Esto significa que las aseveraciones de probabilidad acerca de X y Y deben ser las mismas.



Distribución Uniforme Discreta

- **1.- Distribución Uniforme Discreta** Sea $k > 1$ un número entero. Supongamos que X tiene pmf dado por

$$f(x) = \begin{cases} 1/k & \text{para } 1, \dots, k \\ 0 & \text{en otros casos.} \end{cases}$$

Decimos que X tiene una distribución uniforme sobre $\{1, \dots, k\}$.



Distribución Uniforme Discreta

- **1.- Distribución Uniforme Discreta** Sea $k > 1$ un número entero. Supongamos que X tiene pmf dado por

$$f(x) = \begin{cases} 1/k & \text{para } 1, \dots, k \\ 0 & \text{en otros casos.} \end{cases}$$

Decimos que X tiene una distribución uniforme sobre $\{1, \dots, k\}$.



- **2.-La Distribución de Bernoulli** Sea X que representa un lanzamiento de una moneda. Entonces $\mathbb{P}(X = 1) = p$ y $\mathbb{P}(X = 0) = 1 - p$ para algún $p \in [0, 1]$, entonces decimos que X tiene una distribución de Bernoulli, escrita como $X \sim \text{Bernoulli}$. La función de probabilidad es $f(x) = p^x(1 - p)^{1-x}$ para $x \in \{0, 1\}$.



- **2.-La Distribución de Bernoulli** Sea X que representa un lanzamiento de una moneda. Entonces $\mathbb{P}(X = 1) = p$ y $\mathbb{P}(X = 0) = 1 - p$ para algún $p \in [0, 1]$, entonces decimos que X tiene una distribución de Bernoulli, escrita como $X \sim \text{Bernoulli}$. La función de probabilidad es $f(x) = p^x(1 - p)^{1-x}$ para $x \in \{0, 1\}$.



- **3.- Distribución Binomial** Supongamos que tenemos una moneda, que cae cara con una probabilidad p para algún $0 \leq p \leq 1$. Lanzamos la moneda n veces y sea X el número de caras. Asumimos que esos lanzamientos son independientes. Sea $f(x) = \mathbb{P}(X = x)$, el pmf. Se puede mostrar que

$$f(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & \text{para } x = 0, \dots, n \\ 0 & \text{en otros casos.} \end{cases}$$

- Una variable aleatoria con este pmf es llamada variable aleatoria Binomial y se puede escribir como $X \sim \text{Binomial}(n_1, p)$ y $X_2 \sim \text{Binomial}(n_2, p)$ entonces $X_1 + X_2 \sim \text{Binomial}(n_1 + n_2, p)$.

●



- **3.- Distribución Binomial** Supongamos que tenemos una moneda, que cae cara con una probabilidad p para algún $0 \leq p \leq 1$. Lanzamos la moneda n veces y sea X el número de caras. Asumimos que esos lanzamientos son independientes. Sea $f(x) = \mathbb{P}(X = x)$, el pmf. Se puede mostrar que

$$f(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & \text{para } x = 0, \dots, n \\ 0 & \text{en otros casos.} \end{cases}$$

- Una variable aleatoria con este pmf es llamada variable aleatoria Binomial y se puede escribir como $X \sim \text{Binomial}(n_1, p)$ y $X_2 \sim \text{Binomial}(n_2, p)$ entonces $X_1 + X_2 \sim \text{Binomial}(n_1 + n_2, p)$.



- **3.- Distribución Binomial** Supongamos que tenemos una moneda, que cae cara con una probabilidad p para algún $0 \leq p \leq 1$. Lanzamos la moneda n veces y sea X el número de caras. Asumimos que esos lanzamientos son independientes. Sea $f(x) = \mathbb{P}(X = x)$, el pmf. Se puede mostrar que

$$f(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & \text{para } x = 0, \dots, n \\ 0 & \text{en otros casos.} \end{cases}$$

- Una variable aleatoria con este pmf es llamada variable aleatoria Binomial y se puede escribir como $X \sim \text{Binomial}(n_1, p)$ y $X_2 \sim \text{Binomial}(n_2, p)$ entonces $X_1 + X_2 \sim \text{Binomial}(n_1 + n_2, p)$.



- **4.- Distribución Geométrica** X tiene una distribución geométrica con parámetro $p \in (0, 1)$, escrito como $X \sim \text{Geom}(p)$, si

$$\mathbb{P}(X = k) = p(1 - p)^{k-1}, \quad k \geq 1.$$

Tenemos a partir de esto que

$$\sum_{k=1}^{\infty} \mathbb{P}(X = k) = p \sum_{k=1}^{\infty} (1 - p)^k = \frac{p}{1 - (1 - p)} = 1.$$

Piensa en X como el número de lanzamientos necesarios hasta la primera cara, cuando una moneda es lanzada.



- **4.- Distribución Geométrica** X tiene una distribución geométrica con parámetro $p \in (0, 1)$, escrito como $X \sim \text{Geom}(p)$, si

$$\mathbb{P}(X = k) = p(1 - p)^{k-1}, \quad k \geq 1.$$

Tenemos a partir de esto que

$$\sum_{k=1}^{\infty} \mathbb{P}(X = k) = p \sum_{k=1}^{\infty} (1 - p)^k = \frac{p}{1 - (1 - p)} = 1.$$

Piensa en X como el número de lanzamientos necesarios hasta la primera cara, cuando una moneda es lanzada.



- **5.-La Distribución de Poisson** X tiene una distribución de Poisson con parámetro λ escrita como $X \sim \text{Poisson}(\lambda)$ si

$$f(x) = e^{-\lambda} \frac{\lambda^x}{x!} \quad x \geq 0.$$

Nota que

$$\sum_{k=0}^{\infty} f(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} e^{\lambda} = 1.$$

- La distribución de Poisson es usado a menudo como un modelo para eventos, como decaimiento radiactivo y accidentes de tráfico. Si $X_1 \sim \text{Poisson}(\lambda_1)$ y $X_2 \sim \text{Poisson}(\lambda_2)$ entonces $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$.



- **5.-La Distribución de Poisson** X tiene una distribución de Poisson con parámetro λ escrita como $X \sim \text{Poisson}(\lambda)$ si

$$f(x) = e^{-\lambda} \frac{\lambda^x}{x!} \quad x \geq 0.$$

Nota que

$$\sum_{k=0}^{\infty} f(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} e^{\lambda} = 1.$$

- La distribución de Poisson es usado a menudo como un modelo para eventos, como decaimiento radiactivo y accidentes de tráfico. Si $X_1 \sim \text{Poisson}(\lambda_1)$ y $X_2 \sim \text{Poisson}(\lambda_2)$ entonces $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$.



- **5.-La Distribución de Poisson** X tiene una distribución de Poisson con parámetro λ escrita como $X \sim \text{Poisson}(\lambda)$ si

$$f(x) = e^{-\lambda} \frac{\lambda^x}{x!} \quad x \geq 0.$$

Nota que

$$\sum_{k=0}^{\infty} f(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} e^{\lambda} = 1.$$

- La distribución de Poisson es usado a menudo como un modelo para eventos, como decaimiento radiactivo y accidentes de tráfico. Si $X_1 \sim \text{Poisson}(\lambda_1)$ y $X_2 \sim \text{Poisson}(\lambda_2)$ entonces $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$.



- Definimos las variables aleatorias como una aplicación de un espacio muestral Ω a \mathbb{R} pero no mencionamos el espacio muestral en cualquiera de las distribuciones anteriores.
- El espacio muestral a menudo "desaparece", pero es realmente así. Vamos a construir un espacio de muestra explícito de una variable aleatoria de Bernoulli.
- Sea $\Omega = [0, 1]$ y definamos \mathbb{P} satisfaciendo $\mathbf{P}([a, b]) = b - a$ para $0 \leq a \leq b \leq 1$. Fijemos $p \in [0, 1]$ y definamos

$$X(\omega) = \begin{cases} 1 & \omega \leq p \\ 0 & \omega > p \end{cases}$$

Entonces $\mathbb{P}(X = 1) = \mathbb{P}(\omega \leq p) = \mathbf{P}([0, p]) = p$ y $\mathbb{P}(X = 0) = 1 - p$. Así $X \sim \text{Bernoulli}(p)$.



- Definimos las variables aleatorias como una aplicación de un espacio muestral Ω a \mathbb{R} pero no mencionamos el espacio muestral en cualquiera de las distribuciones anteriores.
- El espacio muestral a menudo "desaparece", pero es realmente así. Vamos a construir un espacio de muestra explícito de una variable aleatoria de Bernoulli.
- Sea $\Omega = [0, 1]$ y definamos \mathbb{P} satisfaciendo $\mathbf{P}([a, b]) = b - a$ para $0 \leq a \leq b \leq 1$. Fijemos $p \in [0, 1]$ y definamos

$$X(\omega) = \begin{cases} 1 & \omega \leq p \\ 0 & \omega > p \end{cases}$$

Entonces $\mathbb{P}(X = 1) = \mathbb{P}(\omega \leq p) = \mathbf{P}([0, p]) = p$ y $\mathbb{P}(X = 0) = 1 - p$. Así $X \sim \text{Bernoulli}(p)$.



- Definimos las variables aleatorias como una aplicación de un espacio muestral Ω a \mathbb{R} pero no mencionamos el espacio muestral en cualquiera de las distribuciones anteriores.
- El espacio muestral a menudo "desaparece", pero es realmente así. Vamos a construir un espacio de muestra explícito de una variable aleatoria de Bernoulli.
- Sea $\Omega = [0, 1]$ y definamos \mathbb{P} satisfaciendo $\mathbf{P}([a, b]) = b - a$ para $0 \leq a \leq b \leq 1$. Fijemos $p \in [0, 1]$ y definamos

$$X(\omega) = \begin{cases} 1 & \omega \leq p \\ 0 & \omega > p \end{cases}$$

Entonces $\mathbb{P}(X = 1) = \mathbb{P}(\omega \leq p) = \mathbf{P}([0, p]) = p$ y $\mathbb{P}(X = 0) = 1 - p$. Así $X \sim \text{Bernoulli}(p)$.



- Definimos las variables aleatorias como una aplicación de un espacio muestral Ω a \mathbb{R} pero no mencionamos el espacio muestral en cualquiera de las distribuciones anteriores.
- El espacio muestral a menudo "desaparece", pero es realmente así. Vamos a construir un espacio de muestra explícito de una variable aleatoria de Bernoulli.
- Sea $\Omega = [0, 1]$ y definamos \mathbb{P} satisfaciendo $\mathbf{P}([a, b]) = b - a$ para $0 \leq a \leq b \leq 1$. Fijemos $p \in [0, 1]$ y definamos

$$X(\omega) = \begin{cases} 1 & \omega \leq p \\ 0 & \omega > p \end{cases}$$

Entonces $\mathbb{P}(X = 1) = \mathbb{P}(\omega \leq p) = \mathbf{P}([0, p]) = p$ y $\mathbb{P}(X = 0) = 1 - p$. Así $X \sim \text{Bernoulli}(p)$.



- **1.- La Distribución Uniforme** X tiene una distribución Uniforme en (a,b) , escrita como $X \sim \text{Uniform}(a, b)$ si

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{para } x \in [a, b] \\ 0 & \text{en otro caso.} \end{cases}$$

donde $a < b$. La función distribución es es

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & x \in [a, b] \\ 1 & x > b \end{cases}$$



- **1.- La Distribución Uniforme** X tiene una distribución Uniforme en (a,b) , escrita como $X \sim \text{Uniform}(a, b)$ si

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{para } x \in [a, b] \\ 0 & \text{en otro caso.} \end{cases}$$

donde $a < b$. La función distribución es es

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & x \in [a, b] \\ 1 & x > b \end{cases}$$



- **2.-Normal (Gaussiana)** X tiene una distribución **Normal (Gaussiana)** con parámetros μ y σ , denotado por $X \sim N(\mu, \sigma^2)$, si

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}, \quad x \in \mathbb{R} \quad (3)$$

donde $\mu \in \mathbb{R}$ y $\sigma > 0$. El parámetro μ es el "centro" (o media) de la distribución y σ es la desviación estándar) de la distribución. La distribución normal juega un papel importante en probabilidad y estadística pues muchos fenómenos en la naturaleza tienen distribuciones aproximadamente normales. Uno de los resultados más importantes de la Estadística el **Teorema del Límite Central** dice que la distribución de una suma de variables aleatorias puede aproximarse por una distribución normal, lo que hace a la distribución Gaussiana muy importante.




- **2.-Normal (Gaussiana)** X tiene una distribución **Normal (Gaussiana)** con parámetros μ y σ , denotado por $X \sim N(\mu, \sigma^2)$, si

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}, \quad x \in \mathbb{R} \quad (3)$$


donde $\mu \in \mathbb{R}$ y $\sigma > 0$. El parámetro μ es el "centro" (o media) de la distribución y σ es la desviación estándar) de la distribución. La distribución normal juega un papel importante en probabilidad y estadística pues muchos fenómenos en la naturaleza tienen distribuciones aproximadamente normales. Uno de los resultados más importantes de la Estadística el **Teorema del Límite Central** dice que la distribución de una suma de variables aleatorias puede aproximarse por una distribución normal, lo que hace a la distribución Gaussiana muy importante.



- Decimos que X tiene una **Distribución Normal Estándar** si $\mu = 0$ y $\sigma = 1$, que se denota como Z . La PDF y CDF de una distribución normal es denotada por $\phi(z)$ y $\Phi(z)$. El PDF de esta distribución es dibujado como



- Decimos que X tiene una **Distribución Normal Estándar** si $\mu = 0$ y $\sigma = 1$, que se denota como Z . La PDF y CDF de una distribución normal es denotada por $\phi(z)$ y $\Phi(z)$. El PDF de esta distribución es dibujado como



● Aquí algunas propiedades

- ① Si $X \sim N(\mu, \sigma^2)$, entonces $Z = (X - \mu)/\sigma \sim N(0, 1)$.
- ② Si $Z \sim N(0, 1)$, entonces $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$.
- ③ Si $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, \dots, n$ son independientes, entonces

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

Se sigue desde 1. que si $X \sim N(\mu, \sigma^2)$ entonces

$$\begin{aligned}\mathbb{P}(a < X < b) &= \mathbb{P}\left(\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}\right) \\ &= \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)\end{aligned}$$

Así podemos calcular las probabilidades, siempre que podamos obtener el CDF de una distribución normal estándar.



• Aquí algunas propiedades

- ① Si $X \sim N(\mu, \sigma^2)$, entonces $Z = (X - \mu)/\sigma \sim N(0, 1)$.
- ② Si $Z \sim N(0, 1)$, entonces $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$.
- ③ Si $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, \dots, n$ son independientes, entonces

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

Se sigue desde 1. que si $X \sim N(\mu, \sigma^2)$ entonces

$$\begin{aligned}\mathbb{P}(a < X < b) &= \mathbb{P}\left(\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}\right) \\ &= \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)\end{aligned}$$

Así podemos calcular las probabilidades, siempre que podamos obtener el CDF de una distribución normal estándar.



• Aquí algunas propiedades

- 1 Si $X \sim N(\mu, \sigma^2)$, entonces $Z = (X - \mu)/\sigma \sim N(0, 1)$.
- 2 Si $Z \sim N(0, 1)$, entonces $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$.
- 3 Si $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, \dots, n$ son independientes, entonces

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

Se sigue desde 1. que si $X \sim N(\mu, \sigma^2)$ entonces

$$\begin{aligned}\mathbb{P}(a < X < b) &= \mathbb{P}\left(\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}\right) \\ &= \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)\end{aligned}$$

Así podemos calcular las probabilidades, siempre que podamos obtener el CDF de una distribución normal estándar.



- Aquí algunas propiedades

- 1 Si $X \sim N(\mu, \sigma^2)$, entonces $Z = (X - \mu)/\sigma \sim N(0, 1)$.
- 2 Si $Z \sim N(0, 1)$, entonces $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$.
- 3 Si $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, \dots, n$ son independientes, entonces

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

Se sigue desde 1. que si $X \sim N(\mu, \sigma^2)$ entonces

$$\begin{aligned}\mathbb{P}(a < X < b) &= \mathbb{P}\left(\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}\right) \\ &= \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)\end{aligned}$$

Así podemos calcular las probabilidades, siempre que podamos obtener el CDF de una distribución normal estándar.



- Aquí algunas propiedades

- 1 Si $X \sim N(\mu, \sigma^2)$, entonces $Z = (X - \mu)/\sigma \sim N(0, 1)$.
- 2 Si $Z \sim N(0, 1)$, entonces $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$.
- 3 Si $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, \dots, n$ son independientes, entonces

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

Se sigue desde 1. que si $X \sim N(\mu, \sigma^2)$ entonces

$$\begin{aligned}\mathbb{P}(a < X < b) &= \mathbb{P}\left(\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}\right) \\ &= \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)\end{aligned}$$

Así podemos calcular las probabilidades, siempre que podamos obtener el CDF de una distribución normal estándar.



- **Ejemplo** Supongamos que $X \sim N(3, 5)$. Encuentra $\mathbb{P}(X > 1)$. La solución es

$$\mathbb{P}(X > 1) = 1 - \mathbb{P}(X < 1) = 1 - \mathbb{P}\left(Z < \frac{1 - 3}{\sqrt{5}}\right) = 1 - \Phi(-0.8944) = 0.81$$

- Ahora encontremos $q = \Phi^{-1}(0.2)$. Esto significa que tenemos que encontrar q tal que $\mathbb{P}(X < q) = 0.2$. Podemos resolver esto, escribiendo

$$0.2 = \mathbb{P}(X < q) = \mathbb{P}\left(Z < \frac{q - \mu}{\sigma}\right) = \Phi\left(\frac{q - \mu}{\sigma}\right).$$

Desde la Tabla Normal, $\Phi(-0.8416) = 0.2$. Por tanto

$$-0.8416 = \frac{q - \mu}{\sigma} = \frac{q - 3}{\sqrt{5}}$$

y así $q = 3 - 0.8416\sqrt{5} = 1.1181$.



- **Ejemplo** Supongamos que $X \sim N(3, 5)$. Encuentra $\mathbb{P}(X > 1)$. La solución es

$$\mathbb{P}(X > 1) = 1 - \mathbb{P}(X < 1) = 1 - \mathbb{P}\left(Z < \frac{1 - 3}{\sqrt{5}}\right) = 1 - \Phi(-0.8944) = 0.81$$

- Ahora encontremos $q = \Phi^{-1}(0.2)$. Esto significa que tenemos que encontrar q tal que $\mathbb{P}(X < q) = 0.2$. Podemos resolver esto, escribiendo

$$0.2 = \mathbb{P}(X < q) = \mathbb{P}\left(Z < \frac{q - \mu}{\sigma}\right) = \Phi\left(\frac{q - \mu}{\sigma}\right).$$

Desde la Tabla Normal, $\Phi(-0.8416) = 0.2$. Por tanto

$$-0.8416 = \frac{q - \mu}{\sigma} = \frac{q - 3}{\sqrt{5}}$$

y así $q = 3 - 0.8416\sqrt{5} = 1.1181$.



- **Ejemplo** Supongamos que $X \sim N(3, 5)$. Encuentra $\mathbb{P}(X > 1)$. La solución es

$$\mathbb{P}(X > 1) = 1 - \mathbb{P}(X < 1) = 1 - \mathbb{P}\left(Z < \frac{1 - 3}{\sqrt{5}}\right) = 1 - \Phi(-0.8944) = 0.81$$

- Ahora encontremos $q = \Phi^{-1}(0.2)$. Esto significa que tenemos que encontrar q tal que $\mathbb{P}(X < q) = 0.2$. Podemos resolver esto, escribiendo

$$0.2 = \mathbb{P}(X < q) = \mathbb{P}\left(Z < \frac{q - \mu}{\sigma}\right) = \Phi\left(\frac{q - \mu}{\sigma}\right).$$

Desde la Tabla Normal, $\Phi(-0.8416) = 0.2$. Por tanto

$$-0.8416 = \frac{q - \mu}{\sigma} = \frac{q - 3}{\sqrt{5}}$$

y así $q = 3 - 0.8416\sqrt{5} = 1.1181$.



- **3.-Distribución Exponencial** X tiene una distribución Exponencial con perímetro β y denotado por $X \sim \text{Exp}(\beta)$, si

$$f(x) = \frac{1}{\beta} e^{-x/\beta}, x > 0$$

donde $\beta > 0$. La distribución exponencial es usado para modelar el tiempo de vida de componentes electrónicos y el tiempo de espera entre ciertos eventos.



- **3.-Distribución Exponencial** X tiene una distribución Exponencial con perímetro β y denotado por $X \sim \text{Exp}(\beta)$, si

$$f(x) = \frac{1}{\beta} e^{-x/\beta}, x > 0$$

donde $\beta > 0$. La distribución exponencial es usado para modelar el tiempo de vida de componentes electrónicos y el tiempo de espera entre ciertos eventos.



- **4.- Distribución Gamma** Para $\alpha > 0$, la **Función Gamma** es definida como $\Gamma(\alpha) = \int_0^{\infty} y^{\alpha-1} e^{-y} dy$. X tiene una distribución Gamma con parámetros α y β denotado por $X \sim \text{Gamma}(\alpha, \beta)$, si

$$f(x) = \frac{1}{\beta^{\alpha} \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta} \quad x > 0$$

donde $\alpha, \beta > 0$. La distribución exponencial es sólo la distribución $\Gamma(1, \beta)$. Si $X_i \sim \text{Gamma}(\alpha_i, \beta)$ son independientes, entonces $\sum_{i=1}^n X_i \sim \text{Gamma}(\sum_{i=1}^n \alpha_i, \beta)$.



- 4.- **Distribución Gamma** Para $\alpha > 0$, la **Función Gamma** es definida como $\Gamma(\alpha) = \int_0^{\infty} y^{\alpha-1} e^{-y} dy$. X tiene una distribución Gamma con parámetros α y β denotado por $X \sim \text{Gamma}(\alpha, \beta)$, si

$$f(x) = \frac{1}{\beta^{\alpha} \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta} \quad x > 0$$

donde $\alpha, \beta > 0$. La distribución exponencial es sólo la distribución $\Gamma(1, \beta)$. Si $X_i \sim \text{Gamma}(\alpha_i, \beta)$ son independientes, entonces $\sum_{i=1}^n X_i \sim \text{Gamma}(\sum_{i=1}^n \alpha_i, \beta)$.



- **5.-Distribución Beta** X tiene una distribución Beta con parámetros $\alpha > 0$ y $\beta > 0$, denotado por $X \sim \text{Beta}(\alpha, \beta)$, si

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1.$$



- **5.-Distribución Beta** X tiene una distribución Beta con parámetros $\alpha > 0$ y $\beta > 0$, denotado por $X \sim \text{Beta}(\alpha, \beta)$, si

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1.$$



- **6.-Distribución t y de Cauchy** X tiene una distribución t con ν grados de libertad, escrito como $X \sim t_\nu$ si

$$f(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})} = \frac{1}{(1 + \frac{x^2}{\nu})^{(\nu+1)/2}}.$$



- **6.-Distribución t y de Cauchy** X tiene una distribución t con ν grados de libertad, escrito como $X \sim t_\nu$ si

$$f(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})} = \frac{1}{(1 + \frac{x^2}{\nu})^{(\nu+1)/2}}.$$



- **La distribución Cauchy** es un caso especial de la distribución t , correspondiendo a $\nu = 1$. La densidad es

$$f(x) = \frac{1}{\pi(1+x^2)}$$

$$\begin{aligned} \int_{-\infty}^{\infty} f(x) dx &= \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{dx}{(1+x^2)} = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{d \tan^{-1}(x)}{dx} \\ &= \frac{1}{\pi} [\tan^{-1}(\infty) - \tan^{-1}(-\infty)] \\ &= \frac{1}{\pi} \left[\frac{\pi}{2} - \left(-\frac{\pi}{2} \right) \right] \\ &= 1. \end{aligned}$$



- **La distribución Cauchy** es un caso especial de la distribución t , correspondiendo a $\nu = 1$. La densidad es

$$f(x) = \frac{1}{\pi(1+x^2)}$$

$$\begin{aligned} \int_{-\infty}^{\infty} f(x) dx &= \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{dx}{(1+x^2)} = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{d \tan^{-1}(x)}{dx} \\ &= \frac{1}{\pi} [\tan^{-1}(\infty) - \tan^{-1}(-\infty)] \\ &= \frac{1}{\pi} \left[\frac{\pi}{2} - \left(-\frac{\pi}{2} \right) \right] \\ &= 1. \end{aligned}$$



- **7.-La Distribución χ^2** X tiene una distribución χ^2 con p grados de libertad, que se escribe como $X \sim \chi_p^2$ si

$$f(x) = \frac{1}{\Gamma(p/2)2^{p/2}} x^{(p/2)-1} e^{-x/2}, \quad x > 0.$$

Si Z_1, \dots, Z_p son variables aleatorias normales estándar independientes entonces $\sum_{i=1}^p Z_i^2 \sim \chi_p^2$.



- **7.-La Distribución χ^2** X tiene una distribución χ^2 con p grados de libertad, que se escribe como $X \sim \chi_p^2$ si

$$f(x) = \frac{1}{\Gamma(p/2)2^{p/2}} x^{(p/2)-1} e^{-x/2}, \quad x > 0.$$

Si Z_1, \dots, Z_p son variables aleatorias normales estándar independientes entonces $\sum_{i=1}^p Z_i^2 \sim \chi_p^2$.



- Dado un par de variables aleatorias discretas X y Y , se define el jdf (*joint mass function*) por $f(x, y) = \mathbb{P}(X = x, Y = y)$.

Ejemplo Aquí una distribución bivariada para dos variables aleatorias X y Y tomando los valores 0 o 1:

	$Y = 0$	$Y = 1$	
$X = 0$	$1/9$	$2/9$	$1/3$
$X = 1$	$2/9$	$4/9$	$2/3$
	$1/3$	$2/3$	1

Así, $f(1, 1) = \mathbb{P}(X = 1, y = 1) = 4/9$.



- Dado un par de variables aleatorias discretas X y Y , se define el jdf (*joint mass function*) por $f(x, y) = \mathbb{P}(X = x, Y = y)$.

Ejemplo Aquí una distribución bivariada para dos variables aleatorias X y Y tomando los valores 0 o 1:

	$Y = 0$	$Y = 1$	
$X = 0$	$1/9$	$2/9$	$1/3$
$X = 1$	$2/9$	$4/9$	$2/3$
	$1/3$	$2/3$	1

Así, $f(1, 1) = \mathbb{P}(X = 1, y = 1) = 4/9$.



- **Definición** En el caso continuo, llamamos a una función $f(x, y)$ un PDF para una variable aleatoria (X, Y) si

- 1 $f(x, y) \geq 0$ para todo (x, y) .
- 2 $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$ y
- 3 Para algún conjunto $A \subset \mathbb{R} \times \mathbb{R}$, $\mathbb{P}((X, Y) \in A) = \int \int_A f(x, y) dx dy$.

Ejemplo Sea (X, Y) que tiene densidad

$$f(x, y) = \begin{cases} cx^2y & \text{si } x^2 \leq y \leq 1 \\ 0 & \text{en otro caso.} \end{cases}$$



- **Definición** En el caso continuo, llamamos a una función $f(x, y)$ un PDF para una variable aleatoria (X, Y) si

- 1 $f(x, y) \geq 0$ para todo (x, y) .
- 2 $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$ y
- 3 Para algún conjunto $A \subset \mathbb{R} \times \mathbb{R}$, $\mathbb{P}((X, Y) \in A) = \int \int_A f(x, y) dx dy$.

Ejemplo Sea (X, Y) que tiene densidad

$$f(x, y) = \begin{cases} cx^2y & \text{si } x^2 \leq y \leq 1 \\ 0 & \text{en otro caso.} \end{cases}$$



- **Definición** En el caso continuo, llamamos a una función $f(x, y)$ un PDF para una variable aleatoria (X, Y) si
 - 1 $f(x, y) \geq 0$ para todo (x, y) .
 - 2 $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$ y
 - 3 Para algún conjunto $A \subset \mathbb{R} \times \mathbb{R}$, $\mathbb{P}((X, Y) \in A) = \int \int_A f(x, y) dx dy$.

Ejemplo Sea (X, Y) que tiene densidad

$$f(x, y) = \begin{cases} cx^2y & \text{si } x^2 \leq y \leq 1 \\ 0 & \text{en otro caso.} \end{cases}$$



- **Definición** En el caso continuo, llamamos a una función $f(x, y)$ un PDF para una variable aleatoria (X, Y) si
 - 1 $f(x, y) \geq 0$ para todo (x, y) .
 - 2 $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$ y
 - 3 Para algún conjunto $A \subset \mathbb{R} \times \mathbb{R}$, $\mathbb{P}((X, Y) \in A) = \int \int_A f(x, y) dx dy$.

Ejemplo Sea (X, Y) que tiene densidad

$$f(x, y) = \begin{cases} cx^2y & \text{si } x^2 \leq y \leq 1 \\ 0 & \text{en otro caso.} \end{cases}$$



- **Definición** En el caso continuo, llamamos a una función $f(x, y)$ un PDF para una variable aleatoria (X, Y) si
 - 1 $f(x, y) \geq 0$ para todo (x, y) .
 - 2 $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$ y
 - 3 Para algún conjunto $A \subset \mathbb{R} \times \mathbb{R}$, $\mathbb{P}((X, Y) \in A) = \int \int_A f(x, y) dx dy$.

Ejemplo Sea (X, Y) que tiene densidad

$$f(x, y) = \begin{cases} cx^2y & \text{si } x^2 \leq y \leq 1 \\ 0 & \text{en otro caso.} \end{cases}$$


•



- Notemos primero que $-1 \leq x \leq 1$. Encontremos el valor de c .
Fijemos un valor x y dejemos que y varíe en su rango, el cuál es $x^2 \leq y \leq 1$.

Así


$$\begin{aligned}
 1 &= \int \int f(x, y) dx dy = c \int_{-1}^1 \int_{x^2}^1 x^2 y dy dx \\
 &= c \int_{-1}^1 x^2 \left[\int_{x^2}^1 y dy \right] dx = c \int_{-1}^1 x^2 \frac{1 - x^4}{2} dx = \frac{4c}{21}.
 \end{aligned}$$



- Notemos primero que $-1 \leq x \leq 1$. Encontremos el valor de c . Fijemos un valor x y dejemos que y varíe en su rango, el cuál es $x^2 \leq y \leq 1$.

Así

$$\begin{aligned}
 1 &= \int \int f(x, y) dx dy = c \int_{-1}^1 \int_{x^2}^1 x^2 y dy dx \\
 &= c \int_{-1}^1 x^2 \left[\int_{x^2}^1 y dy \right] dx = c \int_{-1}^1 x^2 \frac{1 - x^4}{2} dx = \frac{4c}{21}.
 \end{aligned}$$



- Ahora sea $c = 21/4$. Calculemos $\mathbb{P}(X \geq Y)$. Esto corresponde al conjunto $A = \{(x, y); 0 \leq x \leq 1, x^2 \leq y \leq x\}$. (Se puede ver esto, en el diagrama de arriba). Así

$$\begin{aligned}\mathbb{P}(X \geq Y) &= \frac{21}{4} \int_0^1 \int_{x^2}^x x^2 y dy dx = \frac{21}{4} \int_0^1 x^2 \left[\int_{x^2}^x y dy \right] dx \\ &= \frac{21}{4} \int_0^1 x^2 \left(\frac{x^2 - x^4}{2} \right) dx = \frac{3}{20}.\end{aligned}$$



- Ahora sea $c = 21/4$. Calculemos $\mathbb{P}(X \geq Y)$. Esto corresponde al conjunto $A = \{(x, y); 0 \leq x \leq 1, x^2 \leq y \leq x\}$. (Se puede ver esto, en el diagrama de arriba). Así

$$\begin{aligned}\mathbb{P}(X \geq Y) &= \frac{21}{4} \int_0^1 \int_{x^2}^x x^2 y dy dx = \frac{21}{4} \int_0^1 x^2 \left[\int_{x^2}^x y dy \right] dx \\ &= \frac{21}{4} \int_0^1 x^2 \left(\frac{x^2 - x^4}{2} \right) dx = \frac{3}{20}.\end{aligned}$$



- **Definición** Si (X, Y) tiene una distribución bivariada con *jdf* $f_{X,Y}$, entonces el *mmf* *marginal mass function para X* es definido por

$$f_X(x) = \mathbb{P}(X = x) = \sum_y \mathbb{P}(X = x, Y = y) = \sum_y f(x, y) \quad (4)$$

- y la *marginal mass function para Y* es definido por

$$f_Y(y) = \mathbb{P}(Y = y) = \sum_x \mathbb{P}(X = x, Y = y) = \sum_x f(x, y) \quad (5)$$

●



- **Definición** Si (X, Y) tiene una distribución bivariada con *jdf* $f_{X,Y}$, entonces el *mmf* *marginal mass function para X* es definido por

$$f_X(x) = \mathbb{P}(X = x) = \sum_y \mathbb{P}(X = x, Y = y) = \sum_y f(x, y) \quad (4)$$

- y la *marginal mass function para Y* es definido por

$$f_Y(y) = \mathbb{P}(Y = y) = \sum_x \mathbb{P}(X = x, Y = y) = \sum_x f(x, y) \quad (5)$$



- **Definición** Si (X, Y) tiene una distribución bivariada con *jdf* $f_{X,Y}$, entonces el *mmf* *marginal mass function para X* es definido por

$$f_X(x) = \mathbb{P}(X = x) = \sum_y \mathbb{P}(X = x, Y = y) = \sum_y f(x, y) \quad (4)$$

- y la *marginal mass function para Y* es definido por

$$f_Y(y) = \mathbb{P}(Y = y) = \sum_x \mathbb{P}(X = x, Y = y) = \sum_x f(x, y) \quad (5)$$



- **Ejemplo** Supongamos que $f_{X,Y}$ es dado por la tabla siguiente. La distribución marginal para X corresponde a las filas y la distribución marginal para Y corresponde a las columnas.

	$Y = 0$	$Y = 1$	
$X = 0$	$1/10$	$2/10$	$3/10$
$X = 1$	$3/10$	$4/10$	$7/10$
	$4/10$	$6/10$	1

- Por ejemplo, $f_X(0) = 3/10$ y $f_X(1) = 7/10$.

●



- **Ejemplo** Supongamos que $f_{X,Y}$ es dado por la tabla siguiente. La distribución marginal para X corresponde a las filas y la distribución marginal para Y corresponde a las columnas.

	$Y = 0$	$Y = 1$	
$X = 0$	$1/10$	$2/10$	$3/10$
$X = 1$	$3/10$	$4/10$	$7/10$
	$4/10$	$6/10$	1

- Por ejemplo, $f_X(0) = 3/10$ y $f_X(1) = 7/10$.



- **Ejemplo** Supongamos que $f_{X,Y}$ es dado por la tabla siguiente. La distribución marginal para X corresponde a las filas y la distribución marginal para Y corresponde a las columnas.

	$Y = 0$	$Y = 1$	
$X = 0$	$1/10$	$2/10$	$3/10$
$X = 1$	$3/10$	$4/10$	$7/10$
	$4/10$	$6/10$	1

- Por ejemplo, $f_X(0) = 3/10$ y $f_X(1) = 7/10$.



- **Definición** Para variables aleatorias continuas, las densidades marginales son

$$f_X(x) = \int f(x, y) dy \quad f_Y(y) = \int f(x, y) dx \quad (6)$$

Las correspondientes funciones de distribución marginal, son denotadas por F_X y F_Y

Ejemplo Sea (X, Y) tiene densidad

$$f(x, y) = \begin{cases} \frac{21}{4} x^2 y & \text{si } x^2 \leq y \leq 1 \\ 0 & \text{en otros casos.} \end{cases}$$



- **Definición** Para variables aleatorias continuas, las densidades marginales son

$$f_X(x) = \int f(x, y) dy \quad f_Y(y) = \int f(x, y) dx \quad (6)$$

Las correspondientes funciones de distribución marginal, son denotadas por F_X y F_Y

Ejemplo Sea (X, Y) tiene densidad

$$f(x, y) = \begin{cases} \frac{21}{4} x^2 y & \text{si } x^2 \leq y \leq 1 \\ 0 & \text{en otros casos.} \end{cases}$$



- Así

$$f_X(x) = \int f(x, y) dy = \frac{21}{4} x^2 \int_{x^2}^1 y dy = \frac{21}{8} x^2 (1 - x^4)$$

para $-1 \leq x \leq 1$ y $f_X(x) = 0$ en otro caso.

Definición Dos variables aleatorias X y Y son independientes, si para cada A y B

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \mathbb{P}(Y \in B) \quad (7)$$



- Así

$$f_X(x) = \int f(x, y) dy = \frac{21}{4} x^2 \int_{x^2}^1 y dy = \frac{21}{8} x^2 (1 - x^4)$$

para $-1 \leq x \leq 1$ y $f_X(x) = 0$ en otro caso.

Definición Dos variables aleatorias X y Y son independientes, si para cada A y B

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \mathbb{P}(Y \in B) \quad (7)$$



- **Teorema** Sean X y Y tienen un PDF $f_{X,Y}$. Entonces X y Y son independientes si y sólo si $f_{X,Y}(x,y) = f_X(x)f_Y(y)$ para todos los valores de x y y .

Ejemplo Sean X y Y tienen la siguiente distribución

	$Y = 0$	$Y = 1$	
$X = 0$	$1/4$	$1/4$	$1/2$
$X = 1$	$1/4$	$1/4$	$1/2$
	$1/2$	$1/2$	1

Entonces, $f_X(0) = f_X(1) = 1/2$ y $f_Y(0) = f_Y(1) = 1/2$. X y Y son independientes, ya que $f_X(0)f_Y(0) = f(0,0)$, $f_X(0)f_Y(1) = f(0,1)$, $f_X(1)f_Y(0) = f(1,0)$, $f_X(1)f_Y(1) = f(1,1)$.



- **Teorema** Sean X y Y tienen un PDF $f_{X,Y}$. Entonces X y Y son independientes si y sólo si $f_{X,Y}(x,y) = f_X(x)f_Y(y)$ para todos los valores de x y y .

Ejemplo Sean X y Y tienen la siguiente distribución

	$Y = 0$	$Y = 1$	
$X = 0$	1/4	1/4	1/2
$X = 1$	1/4	1/4	1/2
	1/2	1/2	1

Entonces, $f_X(0) = f_X(1) = 1/2$ y $f_Y(0) = f_Y(1) = 1/2$. X y Y son independientes, ya que $f_X(0)f_Y(0) = f(0,0)$, $f_X(0)f_Y(1) = f(0,1)$, $f_X(1)f_Y(0) = f(1,0)$, $f_X(1)f_Y(1) = f(1,1)$.



- Pero si X y Y tienen la misma distribución

	$Y = 0$	$Y = 1$	
$X = 0$	$1/2$	0	$1/2$
$X = 1$	0	$1/2$	$1/2$
	$1/2$	$1/2$	1

ellas no son independientes, ya que $f_X(0)f_Y(1) = (1/2)(1/2) = 1/4$, pero $f(0, 1) = 0$.



- Pero si X y Y tienen la misma distribución

	$Y = 0$	$Y = 1$	
$X = 0$	$1/2$	0	$1/2$
$X = 1$	0	$1/2$	$1/2$
	$1/2$	$1/2$	1

ellas no son independientes, ya que $f_X(0)f_Y(1) = (1/2)(1/2) = 1/4$, pero $f(0, 1) = 0$.



- **Ejemplo** Supongamos que X y Y son independientes y tienen la misma densidad

$$f(x) = \begin{cases} 2x & \text{si } 0 \leq x \leq 1 \\ 0 & \text{en otros casos} \end{cases}$$

- Encontramos $\mathbb{P}(X + Y \leq 1)$. Usando independencia, tenemos que la jdf es

$$f(x, y) = f_X(x)f_Y(y) = \begin{cases} 4xy & \text{si } 0 \leq x \leq 1, \ 0 \leq y \leq 1 \\ 0 & \text{en otros casos.} \end{cases}$$

●



- **Ejemplo** Supongamos que X y Y son independientes y tienen la misma densidad

$$f(x) = \begin{cases} 2x & \text{si } 0 \leq x \leq 1 \\ 0 & \text{en otros casos} \end{cases}$$

- Encontremos $\mathbb{P}(X + Y \leq 1)$. Usando independencia, tenemos que la jdf es

$$f(x, y) = f_X(x)f_Y(y) = \begin{cases} 4xy & \text{si } 0 \leq x \leq 1, \ 0 \leq y \leq 1 \\ 0 & \text{en otros casos.} \end{cases}$$



- **Ejemplo** Supongamos que X y Y son independientes y tienen la misma densidad

$$f(x) = \begin{cases} 2x & \text{si } 0 \leq x \leq 1 \\ 0 & \text{en otros casos} \end{cases}$$

- Encontramos $\mathbb{P}(X + Y \leq 1)$. Usando independencia, tenemos que la jdf es

$$f(x, y) = f_X(x)f_Y(y) = \begin{cases} 4xy & \text{si } 0 \leq x \leq 1, \quad 0 \leq y \leq 1 \\ 0 & \text{en otros casos.} \end{cases}$$



- Ahora,

$$\begin{aligned}\mathbb{P}(X + Y \leq 1) &= \int \int_{x+y \leq 1} f(x, y) dy dx \\ &= 4 \int_0^1 x \left[\int_0^{1-x} y dy \right] dx \\ &= 4 \int_0^1 x \frac{(1-x)^2}{2} dx = \frac{1}{6}.\end{aligned}$$



- Ahora,

$$\begin{aligned}\mathbb{P}(X + Y \leq 1) &= \int \int_{x+y \leq 1} f(x, y) dy dx \\ &= 4 \int_0^1 x \left[\int_0^{1-x} y dy \right] dx \\ &= 4 \int_0^1 x \frac{(1-x)^2}{2} dx = \frac{1}{6}.\end{aligned}$$



- **Teorema** Supongamos que el rango de X y Y es un rectángulo (posiblemente infinito). Si $f(x, y) = g(x)h(y)$ para algún g y h (no necesariamente funciones de densidad) entonces X y Y son independientes.

Ejemplo Sean X y Y con densidad

$$f(x, y) = \begin{cases} 2e^{-(x+2y)} & \text{si } x > 0 \text{ y } y > 0 \\ 0 & \text{en otros casos.} \end{cases}$$

El rango de X y Y es el rectángulo $(0, \infty) \times (0, \infty)$. Podemos escribir $f(x, y) = g(x)h(y)$, donde $g(x) = 2e^{-x}$ y $h(y) = e^{-2y}$. Así, X y Y son independientes.



- **Teorema** Supongamos que el rango de X y Y es un rectángulo (posiblemente infinito). Si $f(x, y) = g(x)h(y)$ para algún g y h (no necesariamente funciones de densidad) entonces X y Y son independientes.

Ejemplo Sean X y Y con densidad

$$f(x, y) = \begin{cases} 2e^{-(x+2y)} & \text{si } x > 0 \text{ y } y > 0 \\ 0 & \text{en otros casos.} \end{cases}$$

El rango de X y Y es el rectángulo $(0, \infty) \times (0, \infty)$. Podemos escribir $f(x, y) = g(x)h(y)$, donde $g(x) = 2e^{-x}$ y $h(y) = e^{-2y}$. Así, X y Y son independientes.



- Si X y Y son discretas, entonces podemos calcular la distribución condicional de X dado que hemos observado $Y = y$. Específicamente, $\mathbb{P}(X = x|Y = y) = \mathbb{P}(X = x, Y = y)/\mathbb{P}(Y = y)$. Esto conduce a la definición cpmf o *Conditional probability mass function*.

Definición La cpmf es

$$f_{X|Y}(x|y) = \mathbb{P}(X = x|Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)} = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

si $f_Y > 0$.

Definición Para variables aleatorias continuas, la cpdf, *Conditional probability density function* es

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

asumiendo que $f_Y(y) > 0$.



- Si X y Y son discretas, entonces podemos calcular la distribución condicional de X dado que hemos observado $Y = y$. Específicamente, $\mathbb{P}(X = x|Y = y) = \mathbb{P}(X = x, Y = y)/\mathbb{P}(Y = y)$. Esto conduce a la definición cpmf o *Conditional probability mass function*.

Definición La cpmf es

$$f_{X|Y}(x|y) = \mathbb{P}(X = x|Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)} = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

si $f_Y > 0$.

Definición Para variables aleatorias continuas, la cpdf, *Conditional probability density function* es

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

asumiendo que $f_Y(y) > 0$.



- Entonces,

$$\mathbb{P}(X \in A | Y = y) = \int_A f_{X|Y}(x|y) dx.$$

- **Ejemplo** Sean X y Y , que tienen una distribución uniforme sobre un cuadrado unidad. Así $f_{X|Y}(x|y) = 1$, para $0 \leq x \leq 1$ y 0 en otros casos. Dado $Y = y$, X es Uniform(0,1). Podemos escribir esto como $X|Y = y \sim \text{Uniform}(0, 1)$.



- Entonces,

$$\mathbb{P}(X \in A | Y = y) = \int_A f_{X|Y}(x|y) dx.$$

- **Ejemplo** Sean X y Y , que tienen una distribución uniforme sobre un cuadrado unidad. Así $f_{X|Y}(x|y) = 1$, para $0 \leq x \leq 1$ y 0 en otros casos. Dado $Y = y$, X es Uniform(0,1). Podemos escribir esto como $X|Y = y \sim \text{Uniform}(0, 1)$.



- Entonces,

$$\mathbb{P}(X \in A | Y = y) = \int_A f_{X|Y}(x|y) dx.$$

- **Ejemplo** Sean X y Y , que tienen una distribución uniforme sobre un cuadrado unidad. Así $f_{X|Y}(x|y) = 1$, para $0 \leq x \leq 1$ y 0 en otros casos. Dado $Y = y$, X es Uniform(0,1). Podemos escribir esto como $X|Y = y \sim \text{Uniform}(0, 1)$.



- **Ejemplo** Supongamos que $X \sim \text{Uniform}(0, 1)$. Después de obtener un valor de X , generamos $Y|X = x \sim \text{Uniform}(x, 1)$. La distribución marginal de Y se puede calcular a partir de

$$f_X(x) = \begin{cases} 1 & \text{si } 0 \leq x \leq 1 \\ 0 & \text{en otros casos.} \end{cases}$$

y

$$f_{Y|X}(y|x) = \begin{cases} \frac{1}{1-x} & \text{si } 0 < x < y < 1 \\ 0 & \text{en otros casos.} \end{cases}$$



- **Ejemplo** Supongamos que $X \sim \text{Uniform}(0, 1)$. Después de obtener un valor de X , generamos $Y|X = x \sim \text{Uniform}(x, 1)$. La distribución marginal de Y se puede calcular a partir de

$$f_X(x) = \begin{cases} 1 & \text{si } 0 \leq x \leq 1 \\ 0 & \text{en otros casos.} \end{cases}$$

y

$$f_{Y|X}(y|x) = \begin{cases} \frac{1}{1-x} & \text{si } 0 < x < y < 1 \\ 0 & \text{en otros casos.} \end{cases}$$



- Así

$$f_{X,Y}(x,y) = f_{Y|X}(y|x)f_X(x) = \begin{cases} \frac{1}{1-x} & \text{si } 0 < x < y < 1 \\ 0 & \text{en otros casos.} \end{cases}$$

La distribución marginal para Y es

$$f_Y(y) = \int_0^y f_{X,Y}(x,y)dx = \int_0^y \frac{dx}{1-x} = - \int_1^{1-y} \frac{du}{u} = -\log(1-y)$$

para $0 < y < 1$.



- Así

$$f_{X,Y}(x,y) = f_{Y|X}(y|x)f_X(x) = \begin{cases} \frac{1}{1-x} & \text{si } 0 < x < y < 1 \\ 0 & \text{en otros casos.} \end{cases}$$

La distribución marginal para Y es

$$f_Y(y) = \int_0^y f_{X,Y}(x,y)dx = \int_0^y \frac{dx}{1-x} = - \int_1^{1-y} \frac{du}{u} = -\log(1-y)$$

para $0 < y < 1$.



- Sea $X = (X_1, \dots, X_n)$ donde X_1, \dots, X_n son variables aleatorias. Llamamos a X **Vector Aleatorio**. $f(x_1, \dots, x_n)$ denota el PDF. Es posible definir los mismos conceptos, de la misma manera que las distribuciones multivariadas. Decimos que X_1, \dots, X_n son independientes si, para cada A_1, \dots, A_n

$$\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n \mathbb{P}(X_i \in A_i). \quad (8)$$

Es suficiente verificar que $f(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$.



- Sea $X = (X_1, \dots, X_n)$ donde X_1, \dots, X_n son variables aleatorias. Llamamos a X **Vector Aleatorio**. $f(x_1, \dots, x_n)$ denota el PDF. Es posible definir los mismos conceptos, de la misma manera que las distribuciones multivariadas. Decimos que X_1, \dots, X_n son independientes si, para cada A_1, \dots, A_n

$$\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n \mathbb{P}(X_i \in A_i). \quad (8)$$

Es suficiente verificar que $f(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$.



- **Definición** Si X_1, \dots, X_n son independientes y cada uno de ellos tiene la misma distribución marginal con CDF F , decimos que X_1, \dots, X_n son idénticamente distribuidas e independientes y escribimos como

$$X_1, \dots, X_n \sim F$$

- Si F tiene densidad f , escribimos también $X_1, \dots, X_n \sim f$. Llamamos a X_1, \dots, X_n una muestra aleatoria de tamaño n desde F .

●



- **Definición** Si X_1, \dots, X_n son independientes y cada uno de ellos tiene la misma distribución marginal con CDF F , decimos que X_1, \dots, X_n son idénticamente distribuidas e independientes y escribimos como

$$X_1, \dots, X_n \sim F$$

- Si F tiene densidad f , escribimos también $X_1, \dots, X_n \sim f$. Llamamos a X_1, \dots, X_n una muestra aleatoria de tamaño n desde F .

●



- **Definición** Si X_1, \dots, X_n son independientes y cada uno de ellos tiene la misma distribución marginal con CDF F , decimos que X_1, \dots, X_n son idénticamente distribuidas e independientes y escribimos como

$$X_1, \dots, X_n \sim F$$

- Si F tiene densidad f , escribimos también $X_1, \dots, X_n \sim f$. Llamamos a X_1, \dots, X_n una muestra aleatoria de tamaño n desde F .



Dos Importantes Distribuciones Multivariadas

- **Multinomial** La versión multivariada de la Binomial, es llamada multinomial. Considere la posibilidad de extraer una bola de una urna que tiene bolas con k colores, etiquetados como 'color 1', 'color 2', ... 'color k '. Sea $p = (p_1, \dots, p_k)$ donde $p_j \geq 0$ y $\sum_{j=1}^k p_j = 1$ y supongamos que p_j es la probabilidad de encontrar una bola de color j . Lanzamos n veces (independientes lanzamientos con reemplazamiento) y sea $X = (X_1, \dots, X_k)$ donde X_j es el número de veces que el color j aparece. Por lo tanto $n = \sum_{j=1}^k X_j$, así decimos que X tiene una distribución Multinomial $\text{Multinomial}(n, p)$. La función probabilidad es

$$f(x) = \binom{n}{x_1 \dots x_k} p_1^{x_1} \cdots p_k^{x_k} \quad (9)$$



Dos Importantes Distribuciones Multivariadas

- Multinomial** La versión multivariada de la Binomial, es llamada multinomial. Considere la posibilidad de extraer una bola de una urna que tiene bolas con k colores, etiquetados como 'color 1', 'color 2', ... 'color k '. Sea $p = (p_1, \dots, p_k)$ donde $p_j \geq 0$ y $\sum_{j=1}^k p_j = 1$ y supongamos que p_j es la probabilidad de encontrar una bola de color j . Lanzamos n veces (independientes lanzamientos con reemplazamiento) y sea $X = (X_1, \dots, X_k)$ donde X_j es el número de veces que el color j aparece. Por lo tanto $n = \sum_{j=1}^k X_j$, así decimos que X tiene una distribución Multinomial $\text{Multinomial}(n, p)$. La función probabilidad es

$$f(x) = \binom{n}{x_1 \dots x_k} p_1^{x_1} \dots p_k^{x_k} \quad (9)$$



- donde

$$\binom{n}{x_1 \dots x_k} = \frac{n!}{x_1! \dots x_k!}.$$

Propiedad Supongamos que $X \sim \text{Multinomial}(n, p)$, donde $X = (X_1, \dots, X_k)$ y $p = (p_1, \dots, p_k)$. La distribución marginal de X_j es Binomial(n, p_j).

- **Normal Multivariada** La distribución normal univariada tiene dos parámetros μ y σ . En la versión multivariada, μ es un vector y σ es reemplazada por una matriz Σ . Para empezar

$$Z = \begin{pmatrix} Z_1 \\ \vdots \\ Z_k \end{pmatrix}$$

donde $Z_1, \dots, Z_k \sim N(0, 1)$ son independientes.



- donde

$$\binom{n}{x_1 \dots x_k} = \frac{n!}{x_1! \dots x_k!}.$$

Propiedad Supongamos que $X \sim \text{Multinomial}(n, p)$, donde $X = (X_1, \dots, X_k)$ y $p = (p_1, \dots, p_k)$. La distribución marginal de X_j es Binomial(n, p_j).

- **Normal Multivariada** La distribución normal univariada tiene dos parámetros μ y σ . En la versión multivariada, μ es un vector y σ es reemplazada por una matriz Σ . Para empezar

$$Z = \begin{pmatrix} Z_1 \\ \vdots \\ Z_k \end{pmatrix}$$

donde $Z_1, \dots, Z_k \sim N(0, 1)$ son independientes.



- donde

$$\binom{n}{x_1 \dots x_k} = \frac{n!}{x_1! \dots x_k!}.$$

Propiedad Supongamos que $X \sim \text{Multinomial}(n, p)$, donde $X = (X_1, \dots, X_k)$ y $p = (p_1, \dots, p_k)$. La distribución marginal de X_j es Binomial(n, p_j).

- **Normal Multivariada** La distribución normal univariada tiene dos parámetros μ y σ . En la versión multivariada, μ es un vector y σ es reemplazada por una matriz Σ . Para empezar

$$Z = \begin{pmatrix} Z_1 \\ \vdots \\ Z_k \end{pmatrix}$$

donde $Z_1, \dots, Z_k \sim N(0, 1)$ son independientes.



- La densidad de Z es

$$\begin{aligned} f(z) &= \prod_{i=1}^k f(z_i) = \frac{1}{(2\pi)^{k/2}} \exp\left\{-\frac{1}{2} \sum_{j=1}^k z_j^2\right\} \\ &= \frac{1}{(2\pi)^{k/2}} \exp\left\{-\frac{1}{2} z^T z\right\}. \end{aligned}$$

- Decimos que Z tiene una distribución multivariada estándar escrita como $Z \sim N(0, I)$, donde 0 representa el vector de K ceros y I es la matriz identidad de orden $k \times k$. De manera más general, un vector X tiene una distribución Normal Multivariada, denotada por $X \sim N(\mu, \Sigma)$, si tiene una densidad

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{k/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)\right\} \quad (10)$$



- La densidad de Z es

$$\begin{aligned} f(z) &= \prod_{i=1}^k f(z_i) = \frac{1}{(2\pi)^{k/2}} \exp\left\{-\frac{1}{2} \sum_{j=1}^k z_j^2\right\} \\ &= \frac{1}{(2\pi)^{k/2}} \exp\left\{-\frac{1}{2} z^T z\right\}. \end{aligned}$$

- Decimos que Z tiene una distribución multivariada estándar escrita como $Z \sim N(0, I)$, donde 0 representa el vector de K ceros y I es la matriz identidad de orden $k \times k$. De manera más general, un vector X tiene una distribución Normal Multivariada, denotada por $X \sim N(\mu, \Sigma)$, si tiene una densidad

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{k/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)\right\} \quad (10)$$



- La densidad de Z es

$$\begin{aligned} f(z) &= \prod_{i=1}^k f(z_i) = \frac{1}{(2\pi)^{k/2}} \exp\left\{-\frac{1}{2} \sum_{j=1}^k z_j^2\right\} \\ &= \frac{1}{(2\pi)^{k/2}} \exp\left\{-\frac{1}{2} z^T z\right\}. \end{aligned}$$

- Decimos que Z tiene una distribución multivariada estándar escrita como $Z \sim N(0, I)$, donde 0 representa el vector de K ceros y I es la matriz identidad de orden $k \times k$. De manera más general, un vector X tiene una distribución Normal Multivariada, denotada por $X \sim N(\mu, \Sigma)$, si tiene una densidad

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{k/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)\right\} \quad (10)$$



- donde $|\Sigma|$, denota el determinante de Σ , μ es un vector de longitud k y Σ es una matriz simétrica, definida positiva. Colocando $\mu = 0$ y $\Sigma = I$ tenemos la distribución Normal Estándar.

desde que $|\Sigma|$ es simétrica y definida positiva, existe una matriz $\Sigma^{1/2}$ llamada la raíz cuadrada de Σ con las siguientes propiedades:

- 1 La matriz $\Sigma^{1/2}$ es simétrica.
- 2 $\Sigma = \Sigma^{1/2}\Sigma^{1/2}$.
- 3 $\Sigma^{1/2}\Sigma^{-1/2} = \Sigma^{-1/2}\Sigma^{1/2} = I$ donde $\Sigma^{-1/2} = (\Sigma^{1/2})^{-1}$



- donde $|\Sigma|$, denota el determinante de Σ , μ es un vector de longitud k y Σ es una matriz simétrica, definida positiva. Colocando $\mu = 0$ y $\Sigma = I$ tenemos la distribución Normal Estándar.

desde que $|\Sigma|$ es simétrica y definida positiva, existe una matriz $\Sigma^{1/2}$ llamada la raíz cuadrada de Σ con las siguientes propiedades:

- 1 La matriz $\Sigma^{1/2}$ es simétrica.
- 2 $\Sigma = \Sigma^{1/2}\Sigma^{1/2}$.
- 3 $\Sigma^{1/2}\Sigma^{-1/2} = \Sigma^{-1/2}\Sigma^{1/2} = I$ donde $\Sigma^{-1/2} = (\Sigma^{1/2})^{-1}$



- donde $|\Sigma|$, denota el determinante de Σ , μ es un vector de longitud k y Σ es una matriz simétrica, definida positiva. Colocando $\mu = 0$ y $\Sigma = I$ tenemos la distribución Normal Estándar.

desde que $|\Sigma|$ es simétrica y definida positiva, existe una matriz $\Sigma^{1/2}$ llamada la raíz cuadrada de Σ con las siguientes propiedades:

- 1 La matriz $\Sigma^{1/2}$ es simétrica.
- 2 $\Sigma = \Sigma^{1/2}\Sigma^{1/2}$.
- 3 $\Sigma^{1/2}\Sigma^{-1/2} = \Sigma^{-1/2}\Sigma^{1/2} = I$ donde $\Sigma^{-1/2} = (\Sigma^{1/2})^{-1}$



- donde $|\Sigma|$, denota el determinante de Σ , μ es un vector de longitud k y Σ es una matriz simétrica, definida positiva. Colocando $\mu = 0$ y $\Sigma = I$ tenemos la distribución Normal Estándar.

desde que $|\Sigma|$ es simétrica y definida positiva, existe una matriz $\Sigma^{1/2}$ llamada la raíz cuadrada de Σ con las siguientes propiedades:

- 1 La matriz $\Sigma^{1/2}$ es simétrica.
- 2 $\Sigma = \Sigma^{1/2}\Sigma^{1/2}$.
- 3 $\Sigma^{1/2}\Sigma^{-1/2} = \Sigma^{-1/2}\Sigma^{1/2} = I$ donde $\Sigma^{-1/2} = (\Sigma^{1/2})^{-1}$



- donde $|\Sigma|$, denota el determinante de Σ , μ es un vector de longitud k y Σ es una matriz simétrica, definida positiva. Colocando $\mu = 0$ y $\Sigma = I$ tenemos la distribución Normal Estándar.

desde que $|\Sigma|$ es simétrica y definida positiva, existe una matriz $\Sigma^{1/2}$ llamada la raíz cuadrada de Σ con las siguientes propiedades:

- 1 La matriz $\Sigma^{1/2}$ es simétrica.
- 2 $\Sigma = \Sigma^{1/2}\Sigma^{1/2}$.
- 3 $\Sigma^{1/2}\Sigma^{-1/2} = \Sigma^{-1/2}\Sigma^{1/2} = I$ donde $\Sigma^{-1/2} = (\Sigma^{1/2})^{-1}$



- **Teorema** Si $Z \sim N(0, I)$ y $X = \mu + \Sigma^{1/2}Z$ entonces $X \sim N(\mu, \Sigma)$.
De otro lado, si $X \sim N(\mu, \Sigma)$ entonces $\Sigma^{-1/2}(X - \mu) \sim N(0, I)$.

Supongamos que particionamos un vector Normal aleatorio X , como $X = (X_a, X_b)$. De manera similar tenemos la partición $\mu = (\mu_a, \mu_b)$ y

$$\Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$$

- **Teorema** Sea $X \sim N(\mu, \Sigma)$. Entonces

- ① La distribución marginal de X_a es $X_a \sim N(\mu_a, \Sigma_{aa})$.
- ② La distribución condicional de X_b dado $X_a = x_a$ es

$$X_b | X_a = x_a \sim N(\mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a), \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}).$$

- ③ Si a es un vector entonces $a^T X \sim N(a^T \mu, a^T \Sigma a)$.
- ④ $V = (X - \mu)^T \Sigma^{-1}(X - \mu) \sim \chi_k^2$.



- **Teorema** Si $Z \sim N(0, I)$ y $X = \mu + \Sigma^{1/2}Z$ entonces $X \sim N(\mu, \Sigma)$.
De otro lado, si $X \sim N(\mu, \Sigma)$ entonces $\Sigma^{-1/2}(X - \mu) \sim N(0, I)$.

Supongamos que particionamos un vector Normal aleatorio X , como $X = (X_a, X_b)$. De manera similar tenemos la partición $\mu = (\mu_a, \mu_b)$ y

$$\Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$$

- **Teorema** Sea $X \sim N(\mu, \Sigma)$. Entonces

- 1 La distribución marginal de X_a es $X_a \sim N(\mu_a, \Sigma_{aa})$.
- 2 La distribución condicional de X_b dado $X_a = x_a$ es

$$X_b|X_a = x_a \sim N(\mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a), \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}).$$

- 3 Si a es un vector entonces $a^T X \sim N(a^T \mu, a^T \Sigma a)$.
- 4 $V = (X - \mu)^T \Sigma^{-1}(X - \mu) \sim \chi_k^2$.



- **Teorema** Si $Z \sim N(0, I)$ y $X = \mu + \Sigma^{1/2}Z$ entonces $X \sim N(\mu, \Sigma)$. De otro lado, si $X \sim N(\mu, \Sigma)$ entonces $\Sigma^{-1/2}(X - \mu) \sim N(0, I)$.

Supongamos que particionamos un vector Normal aleatorio X , como $X = (X_a, X_b)$. De manera similar tenemos la partición $\mu = (\mu_a, \mu_b)$ y

$$\Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$$

- **Teorema** Sea $X \sim N(\mu, \Sigma)$. Entonces

- 1 La distribución marginal de X_a es $X_a \sim N(\mu_a, \Sigma_{aa})$.
- 2 La distribución condicional de X_b dado $X_a = x_a$ es

$$X_b | X_a = x_a \sim N(\mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a), \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}).$$

- 3 Si a es un vector entonces $a^T X \sim N(a^T \mu, a^T \Sigma a)$.
- 4 $V = (X - \mu)^T \Sigma^{-1}(X - \mu) \sim \chi_k^2$.



- **Teorema** Si $Z \sim N(0, I)$ y $X = \mu + \Sigma^{1/2}Z$ entonces $X \sim N(\mu, \Sigma)$.
De otro lado, si $X \sim N(\mu, \Sigma)$ entonces $\Sigma^{-1/2}(X - \mu) \sim N(0, I)$.

Supongamos que particionamos un vector Normal aleatorio X , como $X = (X_a, X_b)$. De manera similar tenemos la partición $\mu = (\mu_a, \mu_b)$ y

$$\Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$$

- **Teorema** Sea $X \sim N(\mu, \Sigma)$. Entonces

- 1 La distribución marginal de X_a es $X_a \sim N(\mu_a, \Sigma_{aa})$.
- 2 La distribución condicional de X_b dado $X_a = x_a$ es

$$X_b|X_a = x_a \sim N(\mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a), \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}).$$

- 3 Si a es un vector entonces $a^T X \sim N(a^T \mu, a^T \Sigma a)$.
- 4 $V = (X - \mu)^T \Sigma^{-1} (X - \mu) \sim \chi_k^2$.



- **Teorema** Si $Z \sim N(0, I)$ y $X = \mu + \Sigma^{1/2}Z$ entonces $X \sim N(\mu, \Sigma)$. De otro lado, si $X \sim N(\mu, \Sigma)$ entonces $\Sigma^{-1/2}(X - \mu) \sim N(0, I)$.

Supongamos que particionamos un vector Normal aleatorio X , como $X = (X_a, X_b)$. De manera similar tenemos la partición $\mu = (\mu_a, \mu_b)$ y

$$\Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$$

- **Teorema** Sea $X \sim N(\mu, \Sigma)$. Entonces

- 1 La distribución marginal de X_a es $X_a \sim N(\mu_a, \Sigma_{aa})$.
- 2 La distribución condicional de X_b dado $X_a = x_a$ es

$$X_b|X_a = x_a \sim N(\mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a), \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}).$$

- 3 Si a es un vector entonces $a^T X \sim N(a^T \mu, a^T \Sigma a)$.
- 4 $V = (X - \mu)^T \Sigma^{-1}(X - \mu) \sim \chi_k^2$.



- **Teorema** Si $Z \sim N(0, I)$ y $X = \mu + \Sigma^{1/2}Z$ entonces $X \sim N(\mu, \Sigma)$. De otro lado, si $X \sim N(\mu, \Sigma)$ entonces $\Sigma^{-1/2}(X - \mu) \sim N(0, I)$.

Supongamos que particionamos un vector Normal aleatorio X , como $X = (X_a, X_b)$. De manera similar tenemos la partición $\mu = (\mu_a, \mu_b)$ y

$$\Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$$

- **Teorema** Sea $X \sim N(\mu, \Sigma)$. Entonces

- 1 La distribución marginal de X_a es $X_a \sim N(\mu_a, \Sigma_{aa})$.
- 2 La distribución condicional de X_b dado $X_a = x_a$ es

$$X_b|X_a = x_a \sim N(\mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a), \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}).$$

- 3 Si a es un vector entonces $a^T X \sim N(a^T \mu, a^T \Sigma a)$.
- 4 $V = (X - \mu)^T \Sigma^{-1}(X - \mu) \sim \chi_k^2$.



- **Teorema** Si $Z \sim N(0, I)$ y $X = \mu + \Sigma^{1/2}Z$ entonces $X \sim N(\mu, \Sigma)$. De otro lado, si $X \sim N(\mu, \Sigma)$ entonces $\Sigma^{-1/2}(X - \mu) \sim N(0, I)$.

Supongamos que particionamos un vector Normal aleatorio X , como $X = (X_a, X_b)$. De manera similar tenemos la partición $\mu = (\mu_a, \mu_b)$ y

$$\Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$$

- **Teorema** Sea $X \sim N(\mu, \Sigma)$. Entonces

- 1 La distribución marginal de X_a es $X_a \sim N(\mu_a, \Sigma_{aa})$.
- 2 La distribución condicional de X_b dado $X_a = x_a$ es

$$X_b|X_a = x_a \sim N(\mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a), \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}).$$

- 3 Si a es un vector entonces $a^T X \sim N(a^T \mu, a^T \Sigma a)$.
- 4 $V = (X - \mu)^T \Sigma^{-1}(X - \mu) \sim \chi_k^2$.



Transformación de Variables Aleatorias

- Supongamos que X es una variable aleatoria con PDF f_X y CDF F_X . Sea $Y = r(X)$ una función de X , llamada una **transformación de X** . Calcular el PDF y CDF de Y en el caso discreto, por ejemplo tenemos

$$\begin{aligned}f_Y(y) &= \mathbb{P}(Y = y) = \mathbb{P}(r(X) = y) \\&= \mathbb{P}(\{x; r(x) = y\}) = \mathbb{P}(X \in r^{-1}(y))\end{aligned}$$

Ejemplo Sea $\mathbb{P}(X = -1) = \mathbb{P}(X = 1) = 1/4$ y $\mathbb{P}(X = 0) = 1/2$. Sea $Y = X^2$. Entonces, $\mathbb{P}(Y = 0) = \mathbb{P}(X = 0) = 1/2$ y $\mathbb{P}(Y = 1) = \mathbb{P}(X = 1) + \mathbb{P}(X = -1) = 1/2$.



Transformación de Variables Aleatorias

- Supongamos que X es una variable aleatoria con PDF f_X y CDF F_X . Sea $Y = r(X)$ una función de X , llamada una **transformación de X** . Calcular el PDF y CDF de Y en el caso discreto, por ejemplo tenemos

$$\begin{aligned} f_Y(y) &= \mathbb{P}(Y = y) = \mathbb{P}(r(X) = y) \\ &= \mathbb{P}(\{x; r(x) = y\}) = \mathbb{P}(X \in r^{-1}(y)) \end{aligned}$$

Ejemplo Sea $\mathbb{P}(X = -1) = \mathbb{P}(X = 1) = 1/4$ y $\mathbb{P}(X = 0) = 1/2$. Sea $Y = X^2$. Entonces, $\mathbb{P}(Y = 0) = \mathbb{P}(X = 0) = 1/2$ y $\mathbb{P}(Y = 1) = \mathbb{P}(X = 1) + \mathbb{P}(X = -1) = 1/2$.



Transformación de Variables Aleatorias

- Supongamos que X es una variable aleatoria con PDF f_X y CDF F_X . Sea $Y = r(X)$ una función de X , llamada una **transformación de X** . Calcular el PDF y CDF de Y en el caso discreto, por ejemplo tenemos

$$\begin{aligned} f_Y(y) &= \mathbb{P}(Y = y) = \mathbb{P}(r(X) = y) \\ &= \mathbb{P}(\{x; r(x) = y\}) = \mathbb{P}(X \in r^{-1}(y)) \end{aligned}$$

Ejemplo Sea $\mathbb{P}(X = -1) = \mathbb{P}(X = 1) = 1/4$ y $\mathbb{P}(X = 0) = 1/2$. Sea $Y = X^2$. Entonces, $\mathbb{P}(Y = 0) = \mathbb{P}(X = 0) = 1/2$ y $\mathbb{P}(Y = 1) = \mathbb{P}(X = 1) + \mathbb{P}(X = -1) = 1/2$.



Resumiendo

x	$f_X(x)$
-1	1/4
0	1/2
1	1/4
y	$f_Y(y)$
0	1/2
1	1/2



- Resumiendo

x	$f_X(x)$
-1	1/4
0	1/2
1	1/4
y	$f_Y(y)$
0	1/2
1	1/2



- Resumiendo

x	$f_X(x)$
-1	1/4
0	1/2
1	1/4
y	$f_Y(y)$
0	1/2
1	1/2



- El caso es continuo, es más difícil. Aquí tres pasos para encontrar f_Y :

- 1 Para cada y , encuentra el conjunto $A_y = \{x : r(x) \leq y\}$.
- 2 Encontrar el CDF

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(r(X) \leq y) \\ &= \mathbb{P}(\{x : r(x) \leq y\}) \\ &= \int_{A_y} f_X(x) dx \end{aligned}$$

- 3 El PDF es $f_Y(y) = F'_Y(y)$.



- El caso es continuo, es más difícil. Aquí tres pasos para encontrar f_Y :

1 Para cada y , encuentra el conjunto $A_y = \{x : r(x) \leq y\}$.

2 Encontrar el CDF

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(r(X) \leq y) \\ &= \mathbb{P}(\{x : r(x) \leq y\}) \\ &= \int_{A_y} f_X(x) dx \end{aligned}$$

3 El PDF es $f_Y(y) = F'_Y(y)$.



- El caso es continuo, es más difícil. Aquí tres pasos para encontrar f_Y :
 - 1 Para cada y , encuentra el conjunto $A_y = \{x : r(x) \leq y\}$.
 - 2 Encontrar el CDF

$$\begin{aligned}
 F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(r(X) \leq y) \\
 &= \mathbb{P}(\{x : r(x) \leq y\}) \\
 &= \int_{A_y} f_X(x) dx
 \end{aligned}$$

- 3 El PDF es $f_Y(y) = F'_Y(y)$.



- El caso es continuo, es más difícil. Aquí tres pasos para encontrar f_Y :
 - 1 Para cada y , encuentra el conjunto $A_y = \{x : r(x) \leq y\}$.
 - 2 Encontrar el CDF

$$\begin{aligned}
 F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(r(X) \leq y) \\
 &= \mathbb{P}(\{x : r(x) \leq y\}) \\
 &= \int_{A_y} f_X(x) dx
 \end{aligned}$$

- 3 El PDF es $f_Y(y) = F'_Y(y)$.



- El caso es continuo, es más difícil. Aquí tres pasos para encontrar f_Y :
 - 1 Para cada y , encuentra el conjunto $A_y = \{x : r(x) \leq y\}$.
 - 2 Encontrar el CDF

$$\begin{aligned}
 F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(r(X) \leq y) \\
 &= \mathbb{P}(\{x : r(x) \leq y\}) \\
 &= \int_{A_y} f_X(x) dx
 \end{aligned}$$

- 3 El PDF es $f_Y(y) = F'_Y(y)$.



- **Ejemplo** Sea $f_X(x) = e^{-x}$ para $x > 0$. Así,
 $F_X(x) = \int_0^x f_X(s)ds = 1 - e^{-x}$. Sea $Y = r(X) = \log(X)$. Entonces
 $A_Y = \{x : x \leq e^y\}$ y

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(\log X \leq y) \\ &= \mathbb{P}(X \leq e^y) = F_X(e^y) = 1 - e^{-e^y}. \end{aligned}$$

Por tanto, $f_Y(y) = e^y e^{-e^y}$ para $y \in \mathbb{R}$.

- Si tenemos por ejemplo, X y Y variables aleatorias, veamos como conocer la distribución de X/Y , $X + Y$, $\max\{X, Y\}$ o $\min\{X, Y\}$.
 Sea $Z = r(X, Y)$, los pasos para encontrar f_Z son los mismo de antes

-



- **Ejemplo** Sea $f_X(x) = e^{-x}$ para $x > 0$. Así,
 $F_X(x) = \int_0^x f_X(s)ds = 1 - e^{-x}$. Sea $Y = r(X) = \log(X)$. Entonces
 $A_Y = \{x : x \leq e^y\}$ y

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(\log X \leq Y) \\ &= \mathbb{P}(X \leq e^y) = F_X(e^y) = 1 - e^{-e^y}. \end{aligned}$$

Por tanto, $f_Y(y) = e^y e^{-e^y}$ para $y \in \mathbb{R}$.

- Si tenemos por ejemplo, X y Y variables aleatorias, veamos como conocer la distribución de X/Y , $X + Y$, $\max\{X, Y\}$ o $\min\{X, Y\}$.
 Sea $Z = r(X, Y)$, los pasos para encontrar f_Z son los mismo de antes



- **Ejemplo** Sea $f_X(x) = e^{-x}$ para $x > 0$. Así,
 $F_X(x) = \int_0^x f_X(s)ds = 1 - e^{-x}$. Sea $Y = r(X) = \log(X)$. Entonces
 $A_Y = \{x : x \leq e^y\}$ y

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(\log X \leq Y) \\ &= \mathbb{P}(X \leq e^y) = F_X(e^y) = 1 - e^{-e^y}. \end{aligned}$$

Por tanto, $f_Y(y) = e^y e^{-e^y}$ para $y \in \mathbb{R}$.

- Si tenemos por ejemplo, X y Y variables aleatorias, veamos como conocer la distribución de X/Y , $X + Y$, $\max\{X, Y\}$ o $\min\{X, Y\}$.
 Sea $Z = r(X, Y)$, los pasos para encontrar f_Z son los mismo de antes



- - 1 Para cada z , encuentra el conjunto $A_z = \{(x, y) : r(x, y) \leq z\}$.
 - 2 Encontrar el CDF

$$\begin{aligned} F_Z(z) &= \mathbb{P}(Z \leq z) = \mathbb{P}(r(X, Y) \leq z) \\ &= \mathbb{P}(\{(x, y) : r(x, y) \leq z\}) \\ &= \int \int_{A_z} f_{X,Y}(x, y) dx dy \end{aligned}$$

- 3 El PDF es $f_Z(z) = F'_Z(z)$.



- - 1 Para cada z , encuentra el conjunto $A_z = \{(x, y) : r(x, y) \leq z\}$.
 - 2 Encontrar el CDF

$$\begin{aligned} F_Z(z) &= \mathbb{P}(Z \leq z) = \mathbb{P}(r(X, Y) \leq z) \\ &= \mathbb{P}(\{(x, y) : r(x, y) \leq z\}) \\ &= \int \int_{A_z} f_{X,Y}(x, y) dx dy \end{aligned}$$

- 3 El PDF es $f_Z(z) = F'_Z(z)$.

•



- 1 Para cada z , encuentra el conjunto $A_z = \{(x, y) : r(x, y) \leq z\}$.
- 2 Encontrar el CDF

$$\begin{aligned}
 F_Z(z) &= \mathbb{P}(Z \leq z) = \mathbb{P}(r(X, Y) \leq z) \\
 &= \mathbb{P}(\{(x, y) : r(x, y) \leq z\}) \\
 &= \int \int_{A_z} f_{X,Y}(x, y) dx dy
 \end{aligned}$$

- 3 El PDF es $f_Z(z) = F'_Z(z)$.



- 1 Para cada z , encuentra el conjunto $A_z = \{(x, y) : r(x, y) \leq z\}$.
- 2 Encontrar el CDF

$$\begin{aligned}
 F_Z(z) &= \mathbb{P}(Z \leq z) = \mathbb{P}(r(X, Y) \leq z) \\
 &= \mathbb{P}(\{(x, y) : r(x, y) \leq z\}) \\
 &= \int \int_{A_z} f_{X,Y}(x, y) dx dy
 \end{aligned}$$

- 3 El PDF es $f_Z(z) = F'_Z(z)$.



- ① Para cada z , encuentra el conjunto $A_z = \{(x, y) : r(x, y) \leq z\}$.
- ② Encontrar el CDF

$$\begin{aligned}
 F_Z(z) &= \mathbb{P}(Z \leq z) = \mathbb{P}(r(X, Y) \leq z) \\
 &= \mathbb{P}(\{(x, y) : r(x, y) \leq z\}) \\
 &= \int \int_{A_z} f_{X,Y}(x, y) dx dy
 \end{aligned}$$

- ③ El PDF es $f_Z(z) = F'_Z(z)$.



- **Ejemplo** Sea $X_1, X_2 \sim \text{Uniform}(0,1)$ independientes. Encontremos la densidad de $Y = X_1 + X_2$ en efecto la jdf de (X_1, X_2) es

$$f(x_1, x_2) = \begin{cases} 1 & 0 < x_1 < 1, 0 < x_2 < 1 \\ 0 & \text{en otros casos} \end{cases}$$

- Sea $r(x_1, x_2) = x_1 + x_2$. Ahora

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(r(X_1, X_2) \leq y) \\ &= \mathbb{P}(\{(x_1, x_2) : r(x_1, x_2) \leq y\}) = \int \int_{A_y} f(x_1, x_2) dx_1 dx_2. \end{aligned}$$

●



- **Ejemplo** Sea $X_1, X_2 \sim \text{Uniform}(0,1)$ independientes. Encontremos la densidad de $Y = X_1 + X_2$ en efecto la jdf de (X_1, X_2) es

$$f(x_1, x_2) = \begin{cases} 1 & 0 < x_1 < 1, 0 < x_2 < 1 \\ 0 & \text{en otros casos} \end{cases}$$

- Sea $r(x_1, x_2) = x_1 + x_2$. Ahora

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(r(X_1, X_2) \leq y) \\ &= \mathbb{P}(\{(x_1, x_2) : r(x_1, x_2) \leq y\}) = \int \int_{A_y} f(x_1, x_2) dx_1 dx_2. \end{aligned}$$



- **Ejemplo** Sea $X_1, X_2 \sim \text{Uniform}(0,1)$ independientes. Encontremos la densidad de $Y = X_1 + X_2$ en efecto la jdf de (X_1, X_2) es



$$f(x_1, x_2) = \begin{cases} 1 & 0 < x_1 < 1, 0 < x_2 < 1 \\ 0 & \text{en otros casos} \end{cases}$$

- Sea $r(x_1, x_2) = x_1 + x_2$. Ahora



$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(r(X_1, X_2) \leq y) \\ &= \mathbb{P}(\{(x_1, x_2) : r(x_1, x_2) \leq y\}) = \int \int_{A_y} f(x_1, x_2) dx_1 dx_2. \end{aligned}$$



- Para encontrar A_y , suponemos primero que $0 < y \leq 1$. Entonces A_y es el triángulo con vértices $(0, 0)$, $(y, 0)$ y $(0, y)$. En este caso $\int \int_{A_y} f(x_1, x_2) dx_1 dx_2$ es el área del triángulo, es decir $y^2/2$. Si $1 < y < 2$, entonces A_y es todo el cuadrado unitario, menos el triángulo con vértices $(1, y-1)$, $(1, 1)$, $(y-1, 1)$. Este conjunto tiene área $1 - (2-y)^2/2$



- Para encontrar A_y , suponemos primero que $0 < y \leq 1$. Entonces A_y es el triángulo con vértices $(0, 0)$, $(y, 0)$ y $(0, y)$. En este caso $\int \int_{A_y} f(x_1, x_2) dx_1 dx_2$ es el área del triángulo, es decir $y^2/2$. Si $1 < y < 2$, entonces A_y es todo el cuadrado unitario, menos el triángulo con vértices $(1, y-1)$, $(1, 1)$, $(y-1, 1)$. Este conjunto tiene área $1 - (2-y)^2/2$



- Por tanto

$$F_Y(y) = \begin{cases} 0 & y < 0 \\ \frac{y^2}{2} & 0 \leq y < 1 \\ 1 - \frac{(2-y)^2}{2} & 1 \leq y < 2 \\ 1 & y \geq 2 \end{cases}$$

- Por diferenciación el PDF es

$$f_Y(y) = \begin{cases} y & 0 \leq y \leq 1 \\ 2 - y & 1 \leq y \leq 2 \\ 0 & \text{en otros casos.} \end{cases}$$



- Por tanto

$$F_Y(y) = \begin{cases} 0 & y < 0 \\ \frac{y^2}{2} & 0 \leq y < 1 \\ 1 - \frac{(2-y)^2}{2} & 1 \leq y < 2 \\ 1 & y \geq 2 \end{cases}$$

- Por diferenciación el PDF es

$$f_Y(y) = \begin{cases} y & 0 \leq y \leq 1 \\ 2 - y & 1 \leq y \leq 2 \\ 0 & \text{en otros casos.} \end{cases}$$



Ejercicios

Eje.1 Sea X una variable aleatoria de un espacio de probabilidad dado y sea $a \in \mathbb{R}$. Muestra que

- 1 aX es una variable aleatoria.
- 2 $X - X$, es una variable aleatoria tomando el valor de 0 y $X + X = 2X$.

Eje.2 Sea X una variable aleatoria y sea $g : \mathbb{R} \rightarrow \mathbb{R}$ continua y estrictamente creciente. Muestra que $Y = g(X)$ es una variable aleatoria.

Eje.3 Muestra que, si X y Y son variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, entonces lo son $X + Y$, XY y $\min\{X, Y\}$.

Eje.4 Prueba que el conjunto de todas las variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, constituye un espacio vectorial sobre los reales. Si Ω es finito, escribe una base para ese espacio.



Ejercicios

Eje.1 Sea X una variable aleatoria de un espacio de probabilidad dado y sea $a \in \mathbb{R}$. Muestra que

① aX es una variable aleatoria.

② $X - X$, es una variable aleatoria tomando el valor de 0 y $X + X = 2X$.

Eje.2 Sea X una variable aleatoria y sea $g : \mathbb{R} \rightarrow \mathbb{R}$ continua y estrictamente creciente. Muestra que $Y = g(X)$ es una variable aleatoria.

Eje.3 Muestra que, si X y Y son variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, entonces lo son $X + Y$, XY y $\min\{X, Y\}$.

Eje.4 Prueba que el conjunto de todas las variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, constituye un espacio vectorial sobre los reales. Si Ω es finito, escribe una base para ese espacio.



Ejercicios

Eje.1 Sea X una variable aleatoria de un espacio de probabilidad dado y sea $a \in \mathbb{R}$. Muestra que

① aX es una variable aleatoria.

② $X - X$, es una variable aleatoria tomando el valor de 0 y $X + X = 2X$.

Eje.2 Sea X una variable aleatoria y sea $g : \mathbb{R} \rightarrow \mathbb{R}$ continua y estrictamente creciente. Muestra que $Y = g(X)$ es una variable aleatoria.

Eje.3 Muestra que, si X y Y son variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, entonces lo son $X + Y$, XY y $\min\{X, Y\}$.

Eje.4 Prueba que el conjunto de todas las variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, constituye un espacio vectorial sobre los reales. Si Ω es finito, escribe una base para ese espacio.



Ejercicios

Eje.1 Sea X una variable aleatoria de un espacio de probabilidad dado y sea $a \in \mathbb{R}$. Muestra que

- ① aX es una variable aleatoria.
- ② $X - X$, es una variable aleatoria tomando el valor de 0 y $X + X = 2X$.

Eje.2 Sea X una variable aleatoria y sea $g : \mathbb{R} \rightarrow \mathbb{R}$ continua y estrictamente creciente. Muestra que $Y = g(X)$ es una variable aleatoria.

Eje.3 Muestra que, si X y Y son variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, entonces lo son $X + Y$, XY y $\min\{X, Y\}$.

Eje.4 Prueba que el conjunto de todas las variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, constituye un espacio vectorial sobre los reales. Si Ω es finito, escribe una base para ese espacio.



Ejercicios

Eje.1 Sea X una variable aleatoria de un espacio de probabilidad dado y sea $a \in \mathbb{R}$. Muestra que

- ① aX es una variable aleatoria.
- ② $X - X$, es una variable aleatoria tomando el valor de 0 y $X + X = 2X$.

Eje.2 Sea X una variable aleatoria y sea $g : \mathbb{R} \rightarrow \mathbb{R}$ continua y estrictamente creciente. Muestra que $Y = g(X)$ es una variable aleatoria.

Eje.3 Muestra que, si X y Y son variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, entonces lo son $X + Y$, XY y $\min\{X, Y\}$.

Eje.4 Prueba que el conjunto de todas las variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, constituye un espacio vectorial sobre los reales. Si Ω es finito, escribe una base para ese espacio.



Ejercicios

- Eje.1** Sea X una variable aleatoria de un espacio de probabilidad dado y sea $a \in \mathbb{R}$. Muestra que
- 1 aX es una variable aleatoria.
 - 2 $X - X$, es una variable aleatoria tomando el valor de 0 y $X + X = 2X$.
- Eje.2** Sea X una variable aleatoria y sea $g : \mathbb{R} \rightarrow \mathbb{R}$ continua y estrictamente creciente. Muestra que $Y = g(X)$ es una variable aleatoria.
- Eje.3** Muestra que, si X y Y son variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, entonces lo son $X + Y$, XY y $\min\{X, Y\}$.
- Eje.4** Prueba que el conjunto de todas las variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, constituye un espacio vectorial sobre los reales. Si Ω es finito, escribe una base para ese espacio.



Ejercicios

- Eje.1** Sea X una variable aleatoria de un espacio de probabilidad dado y sea $a \in \mathbb{R}$. Muestra que
- 1 aX es una variable aleatoria.
 - 2 $X - X$, es una variable aleatoria tomando el valor de 0 y $X + X = 2X$.
- Eje.2** Sea X una variable aleatoria y sea $g : \mathbb{R} \rightarrow \mathbb{R}$ continua y estrictamente creciente. Muestra que $Y = g(X)$ es una variable aleatoria.
- Eje.3** Muestra que, si X y Y son variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, entonces lo son $X + Y$, XY y $\min\{X, Y\}$.
- Eje.4** Prueba que el conjunto de todas las variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{R})$, constituye un espacio vectorial sobre los reales. Si Ω es finito, escribe una base para ese espacio.



- Eje.5 Sean X y Y variables aleatorias independientes de Poisson con sus respectivos parámetros λ y μ . Muestra que $X + Y$ es de Poisson, con parámetro $\lambda + \mu$.
- Eje.6 Muestra que la suma de las variables binomiales $\text{bin}(m, p)$ y $\text{bin}(n, p)$ respectivamente es $\text{bin}(m + n, p)$.
- Eje.7 Un artista de feria afirma tener el poder de la telekinesis. La multitud se lanza monedas y él hace que la moneda muestre cara. Sucede de cinco de seis veces. ¿Qué posibilidades tendría de hacer esto si él no tiene ese poder.



- Eje.5 Sean X y Y variables aleatorias independientes de Poisson con sus respectivos parámetros λ y μ . Muestra que $X + Y$ es de Poisson, con parámetro $\lambda + \mu$.
- Eje.6 Muestra que la suma de las variables binomiales $\text{bin}(m, p)$ y $\text{bin}(n, p)$ respectivamente es $\text{bin}(m + n, p)$.
- Eje.7 Un artista de feria afirma tener el poder de la telekinesis. La multitud se lanza monedas y él hace que la moneda muestre cara. Sucede de cinco de seis veces. ¿Qué posibilidades tendría de hacer esto si él no tiene ese poder.



- Eje.5 Sean X y Y variables aleatorias independientes de Poisson con sus respectivos parámetros λ y μ . Muestra que $X + Y$ es de Poisson, con parámetro $\lambda + \mu$.
- Eje.6 Muestra que la suma de las variables binomiales $\text{bin}(m, p)$ y $\text{bin}(n, p)$ respectivamente es $\text{bin}(m + n, p)$.
- Eje.7 Un artista de feria afirma tener el poder de la telekinesis. La multitud se lanza monedas y él hace que la moneda muestre cara. Sucede de cinco de seis veces. ¿Qué posibilidades tendría de hacer esto si él no tiene ese poder.



- Eje.5 Sean X y Y variables aleatorias independientes de Poisson con sus respectivos parámetros λ y μ . Muestra que $X + Y$ es de Poisson, con parámetro $\lambda + \mu$.
- Eje.6 Muestra que la suma de las variables binomiales $\text{bin}(m, p)$ y $\text{bin}(n, p)$ respectivamente es $\text{bin}(m + n, p)$.
- Eje.7 Un artista de feria afirma tener el poder de la telekinesis. La multitud se lanza monedas y él hace que la moneda muestre cara. Sucede de cinco de seis veces. ¿Qué posibilidades tendría de hacer esto si él no tiene ese poder.



Eje.8



Eje.8















